Fast Computation of Wasserstein Barycenters

Synthèse et analyse de l'article (Cuturi & Doucet, ICML 2014)

Présenté par : SOULEYMAN

Master Mathématiques Appliquées et Statistique
Université de Bordeaux

06 Novembre 2025

1. Introduction

Problématique : Calculer une moyenne géométriquement cohérente entre plusieurs distributions.

Contexte : Avant 2014, les méthodes de transport optimal étaient coûteuses.

Objectif de Cuturi & Doucet (2014) : accélérer le calcul des barycentres grâce à une **régularisation entropique**.

Applications : apprentissage automatique, traitement d'images, clustering, modélisation statistique.

Exemple illustratif : barycentres d'images

Figure : Moyennes de 30 images d'ellipses (Cuturi & Doucet, 2014) :

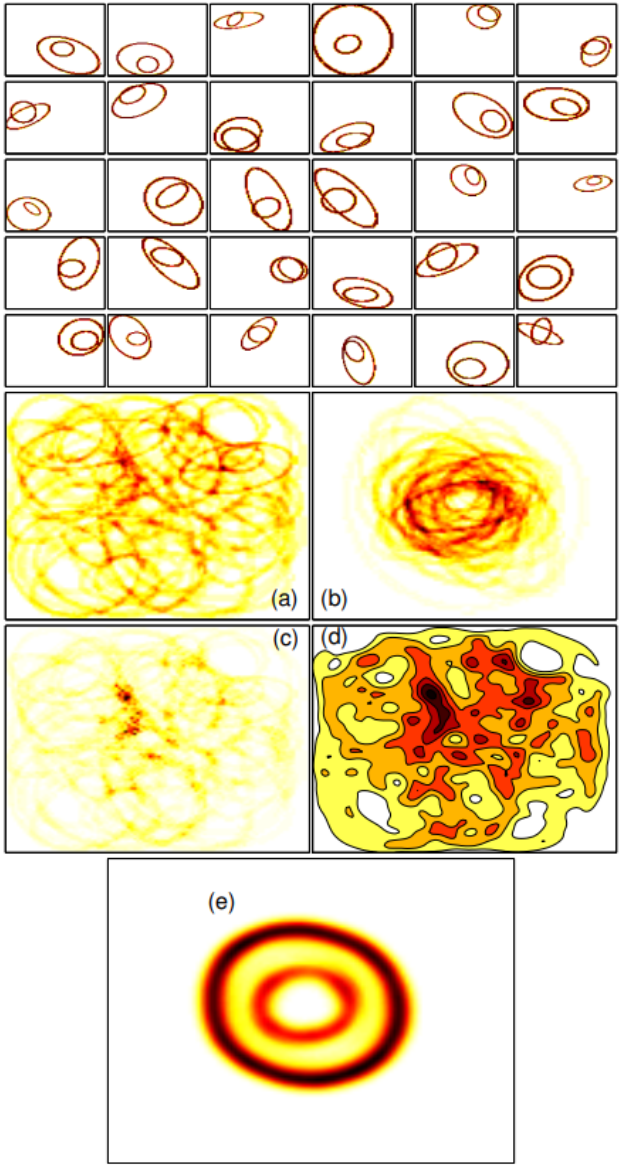
(a) Distance euclidienne simple

(b) Euclidienne centrée

(c) Jeffrey centroid

(d) RKHS distance (noyau gaussien)

(e) 2-Wasserstein distance



$\rightarrow$ *Le barycentre de Wasserstein capture fidèlement la structure des données : la structure géométrique des images ; la cohérence spatiale ; la forme des ellipses.*

Situation de l'article

Titre : *Fast Computation of Wasserstein Barycenters*

Auteurs : Marco Cuturi, Arnaud Doucet

Conférence : ICML 2014 (Pékin)

Éditeur : Proceedings of Machine Learning Research (PMLR)

Thème : Transport optimal et apprentissage statistique

Impact : +1000 citations, référence majeure en transport optimal computationnel

Les auteurs

Marco Cuturi

En 2014 : Kyoto University

Aujourd'hui : ENSAE–CREST, Apple ML Research

Travaux : transport optimal, distances entropiques

Arnaud Doucet

En 2014 : University of Oxford

Aujourd'hui : Google DeepMind, Oxford

Travaux : inférence bayésienne, MCMC, filtrage particulaire

2.1 Définition : Distance de Wasserstein

Définition 1 (Villani, 2009)

Pour $p \geq 1$, et $\mu, \nu \in \mathcal{P}(\Omega)$,

$$W_p(\mu, \nu) = \left(\inf_{\pi \in \Pi(\mu,\nu)} \int_{\Omega^2} D(x,y)^p \, d\pi(x,y) \right)^{1/p}$$

$\Pi(\mu, \nu)$: ensemble des plans de transport admissibles.

W_p : coût minimal pour déplacer la masse de μ vers ν.

2.2 Restriction aux mesures empiriques

$$\mu = \sum_{i=1}^{n} a_i \delta_{x_i}, \quad \nu = \sum_{j=1}^{m} b_j \delta_{y_j}$$

$$W_p^p(\mu, \nu) = \min_{T \in U(a,b)} \langle T, M_{XY} \rangle$$

où :

$$U(a,b) = \{T \geq 0 \mid T1_m = a,\ T^T 1_n = b\}, \quad M_{XY}[i,j] = D(x_i, y_j)^p.$$

$\rightarrow$ C'est un programme linéaire appelé *transport problem*.

3.1 Définition du barycentre de Wasserstein

Définition (Agueh & Carlier, 2011)

Pour N mesures $\nu_1, \ldots, \nu_N$, le barycentre de Wasserstein est :

$$\mu^\star = \arg\min_{\mu} \frac{1}{N} \sum_{i=1}^{N} W_p^p(\mu, \nu_i)$$

Intuition : ce barycentre représente une mesure moyenne qui minimise la somme des distances de Wasserstein aux mesures données.

3.2 Travaux antérieurs et position de l'article

Travaux clés :

Agueh & Carlier (2011) : existence et unicité du barycentre.

Rabin et al. (2012) : approche rapide par la *distance de Wasserstein tranchée*, po des espaces de faible dimension.

Cuturi (2013) : introduction de la régularisation entropique pour le transport optimal.

→ **Objectif de l'article (Cuturi & Doucet, 2014) :** Étendre cette régularisation au calcul des barycentres pour obtenir une méthode rapide, différentiable et numériquement stable.

3. Méthodologie et motivation

Objectif des auteurs

Rendre le calcul des barycentres de Wasserstein **rapide**, **stable** et **différentiable**.

Problème classique : le transport optimal exact a une complexité de $O(n^3)$, donc peu adapté aux grandes bases (images, données spatiales, etc.).

Solution proposée :

introduire une **régularisation entropique** pour lisser la fonction de coût ;

rendre le problème **strictement convexe et différentiable** ;

utiliser un algorithme matriciel rapide : **Sinkhorn scaling** ($O(n^2)$).

$\rightarrow$ La régularisation entropique transforme un problème linéaire lourd en un problème lisse optimisable efficacement.

4. Régularisation entropique et algorithme de Sinkhorn

Formulation régularisée (Cuturi, 2013–2014) :

$$p_\lambda(a, b; M) = \min_{T \in U(a,b)} \langle T, M \rangle - \frac{1}{\lambda} h(T), \quad h(T) = -\sum_{i,j} t_{ij} \log t_{ij}.$$

Solutions optimales :

$$T_\lambda^* = \mathrm{diag}(u) K \mathrm{diag}(v), \quad K = e^{-\lambda M}.$$

Itérations de Sinkhorn :

$$u \leftarrow \frac{a}{Kv}, \quad v \leftarrow \frac{b}{K^T u}.$$

Propriétés :

- Convergence linéaire prouvée (Franklin & Lorenz, 1989).
- Complexité réduite à $O(n^2)$.
- Calcul différentiable, donc utilisable dans le **deep learning**.

4. Cas du support fixe

Principe

Le support X est **fixé** : seuls les poids a sont mis à jour.

Objectif : minimiser une fonction convexe de a via :

une **méthode de sous-gradient** ;

une **projection de Bregman** sur le simplexe.

$$a \leftarrow a \odot \exp(-t_0 \alpha); \quad a \leftarrow \frac{a}{\sum_j a_j}.$$

Remarque : cette méthode est analogue à une mise à jour de poids dans un modèle à support constant, avec accélération de **Nesterov** pour une convergence plus rapide.

5. Cas du support libre

Principe général

Le support X est **libre** : ses positions et les poids a sont optimisés conjointement.

Mise à jour des poids a (comme dans le cas fixe).

Mise à jour des positions X à partir des transports optimaux :

$$X \leftarrow (1-\theta)X + \theta \left(\frac{1}{N} \sum_{i=1}^{N} Y_i T_i^{*T} \mathrm{diag}(a^{-1}) \right).$$

chaque point du support devient un barycentre pondéré des points d'entrée Y_i ;

la dimension du support (k) contrôle la granularité du barycentre ;

généralisation géométrique du **k-means**.

6.1 Visualisation d'images perturbées (MNIST)

Données : 50,000 images MNIST (5,000 par chiffre).

Paramètres :

$$\lambda = \frac{60}{\text{median}(M)} \quad \text{et} \quad M = \text{matrice des distances euclidiennes carrées.}$$

Temps de calcul : environ 2h (100 itérations) sur GPU Quadro K5000.

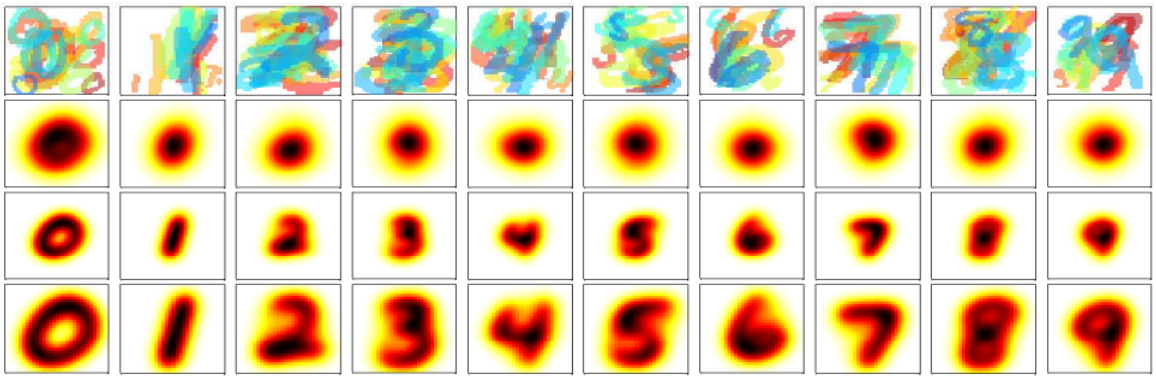


Figure : Barycentres entropiques des chiffres MNIST.

Observation : les barycentres se stabilisent après une soixantaine d'itérations.

6.2 Support libre : Clustering de données de recensement

Motivation : éviter des clusters déséquilibrés dans le k-means classique.

Idée :

Contraindre les poids à être uniformes : $\Theta = \{1_k/k\}$.

Comparer avec le cas libre : $\Theta = \Sigma_k$.

Données : recensement américain (revenu et population sur 57,647 points dans 48 États contigus).

Les poids des points sont proportionnels aux valeurs mesurées.

Initialisation : centroids = capitales d'États.

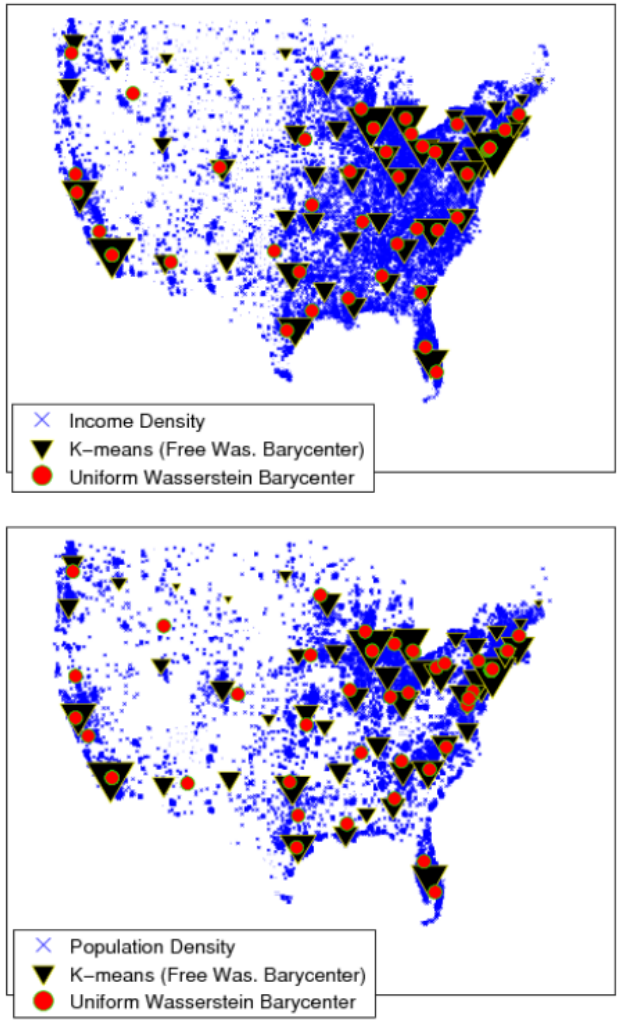
Résultats du Clustering

Figure 3. Comparaison entre :

Barycentres de type k-means (triangles, masse libre),

Barycentres uniformes (points rouges, masse contrainte).

Les barycentres uniformes induisent un **clustering équilibré** : chaque cellule contient la même masse totale (revenu ou population).



Convergence des Méthodes

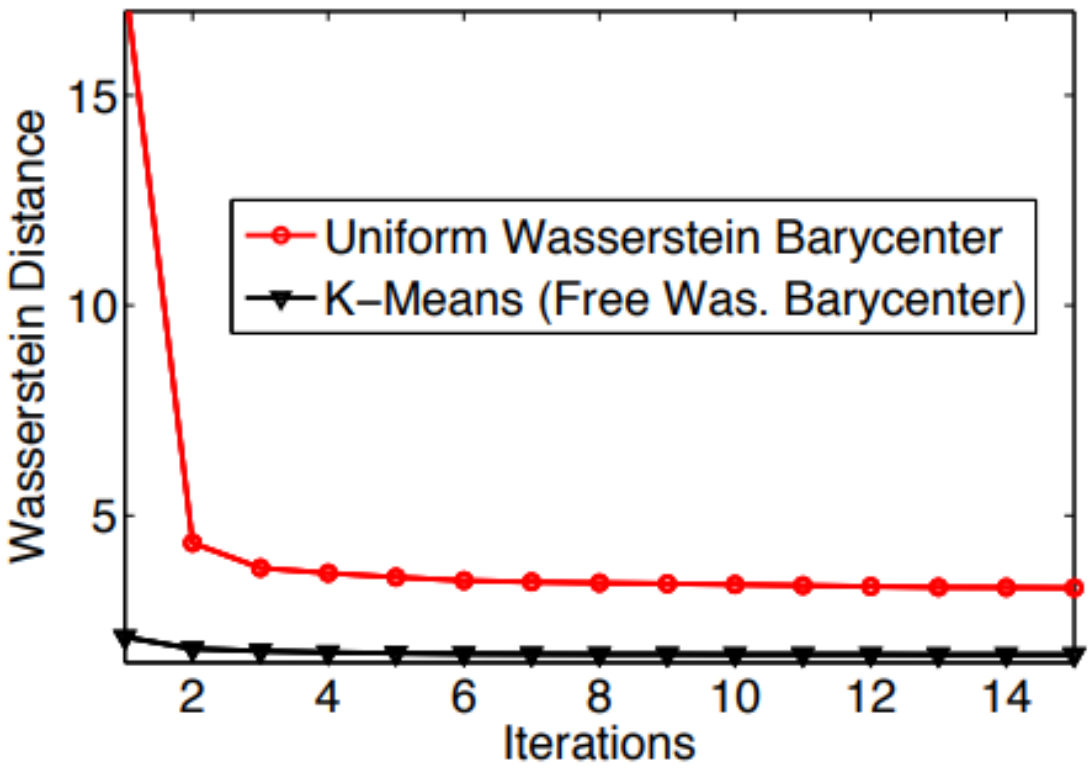


Figure 4. Comparaison des distances de Wasserstein : Barycentre uniforme ($\Theta = \{1_k/k\}$) et k-means (Wasserstein libre).
Résultat : l'approche uniforme converge à une vitesse similaire au k-means, avec un léger surcoût (12.5 s vs 1.55 s par itération CPU).

5. Conclusion

Deux algorithmes proposés pour calculer les barycentres de Wasserstein à partir de mesures empiriques.

Méthodes adaptées aux problèmes de grande dimension et mathématiquement rigoureuses.

Lenteur initiale du subgradient et nécessité de résoudre plusieurs transports optimaux.

Introduction d'une régularisation entropique et d'une formulation duale plus efficace.

Applications possibles au clustering équilibré, à la visualisation et à la propagation de Wasserstein.