



Rapport de Projet

Défi IA 2025 – CNES

Trouver de l'eau et des nuages dans les atmosphères d'exoplanètes

Dades Marwa et Mahamat Youssouf soulayman

Master Mathématiques Appliquées et Statistique — Université de Bordeaux

Parcours : Modélisation Statistique et Stochastique (MSS)

UE : Projet Données Massives

Tuteur : Jérémie Bigot

26 janvier 2026

Résumé

Ce rapport présente l'analyse statistique, l'exploration des données, les choix méthodologiques et les modèles développés dans le cadre du Défi IA 2025 du CNES. L'objectif consiste à déterminer automatiquement la présence d'eau et de nuages dans les atmosphères d'exoplanètes, à partir de spectres simulés de la mission spatiale ARIEL. Nous décrivons successivement les données, les analyses préliminaires, les modèles testés, leur optimisation ainsi que les performances obtenues.

Table des matières

1 Introduction **4**

2 Description des données **4**
2.1 Spectres 4
2.2 Données auxiliaires 5
2.3 Fichiers fournis 6

3 Statistiques descriptives **6**
3.1 Distribution des classes 6
3.1.1 Présence d'eau 6
3.1.2 Présence de nuages 7
3.2 Analyse de la variabilité des spectres 7
3.3 Réduction de dimension des spectres par ACP 8
3.4 Analyse des vecteurs propres de l'ACP 9
3.5 Analyse exploratoire des variables auxiliaires 10
3.6 Relations entre paramètres astrophysiques 10
3.7 Synthèse de l'analyse descriptive 11

4 Prétraitement et normalisation **12**
4.1 Transformation des données auxiliaires 12
4.1.1 Changement d'unités et mise à l'échelle physique 12
4.1.2 Calcul du rayon théorique de la planète 13
4.1.3 Sélection des variables finales 13
4.2 Normalisation des données 13
4.2.1 Normalisation des données spectrales 14
4.2.2 Normalisation des données auxiliaires 14

5 Comparaison et choix des modèles **14**
5.1 Comparaison des modèles de classification 14
5.1.1 Random Forest 14
5.1.2 Gradient Boosting 15
5.1.3 Gradient Boosting avec réduction de dimension 16
5.2 Analyse des performances des modèles 16
5.3 Choix du modèle final 16

6 Stratégie d'optimisation et validation **17**
6.1 Validation croisée et séparation des classes 17
6.2 Optimisation des seuils de décision 17
6.3 Résultats du modèle optimisé 17
6.4 Modèle final et soumission Kaggle 17
6.5 Bilan méthodologique 18

7 Conclusion **18**

1 Introduction

La mission **ARIEL** (Atmospheric Remote-sensing Infrared Exoplanet Large-survey) de l'Agence Spatiale Européenne (ESA), dont le lancement est prévu en 2029, vise à caractériser l'atmosphère d'environ mille exoplanètes. L'instrument observe les transits planétaires : lorsque la planète passe devant son étoile, une partie de la lumière est absorbée par son atmosphère, produisant un *spectre de transit* contenant l'empreinte moléculaire des gaz présents.

Dans le cadre du **Défi IA 2025**, proposé par le CNES, il s'agit à partir de données simulées provenant du logiciel Taurex, d'entraîner un modèle d'apprentissage automatique capable de prédire deux éléments essentiels de l'atmosphère d'une exoplanète :

— la présence ou l'absence d'eau ;
— la présence ou l'absence de nuages.

Ces prédictions sont obtenues à partir :

— d'un spectre de 52 longueurs d'onde provenant des instruments FGS et AIRS ;
— de données auxiliaires décrivant le système étoile–planète.

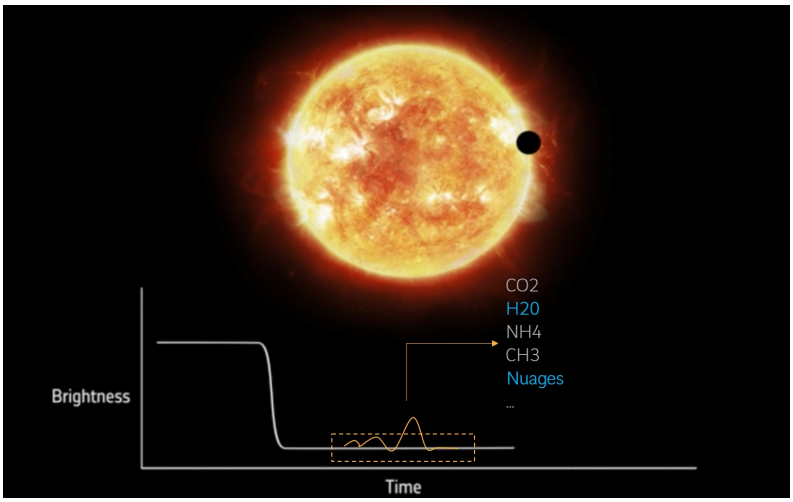


FIGURE 1 – Schéma du transit d'une exoplanète devant son étoile.

Ce rapport présente le cheminement complet du projet : compréhension des données, statistiques descriptives, choix des modèles, optimisation, et performances finales.

2 Description des données

Le jeu de données fourni pour ce défi comporte deux sources d'information complémentaires : (1) les spectres simulés et (2) les données auxiliaires du système planétaire.

2.1 Spectres

Chaque observation contient un spectre de transit composé de **52 longueurs d'onde**. Ces longueurs d'onde proviennent de deux instruments :

— FGS (caméra visible) : 1.1 à 1.95 μm ;
— AIRS (spectromètre infrarouge) : 1.95 à 7.8 μm.

Chaque point spectral comporte trois valeurs :

— la profondeur moyenne de transit ;

— une estimation de l'incertitude basse ;
— une estimation de l'incertitude haute.

Ainsi, le fichier `spectra.npy` a une dimension :

$$(X,\ 52,\ 3)$$

où X est le nombre de planètes observées (3000 pour l'entraînement).

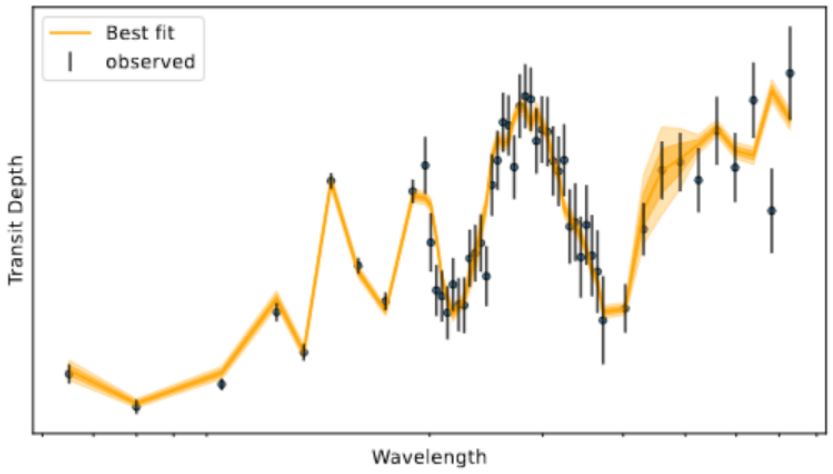


FIGURE 2 – Exemple de spectre simulé.

2.2 Données auxiliaires

En complément du spectre, cinq paramètres astrophysiques sont fournis pour chaque système :

— masse de l'étoile hôte ;
— rayon de l'étoile hôte ;
— température de l'étoile ;
— masse de la planète ;
— demi-grand axe de l'orbite.

Ces valeurs apportent un contexte essentiel pour interpréter physiquement le spectre.

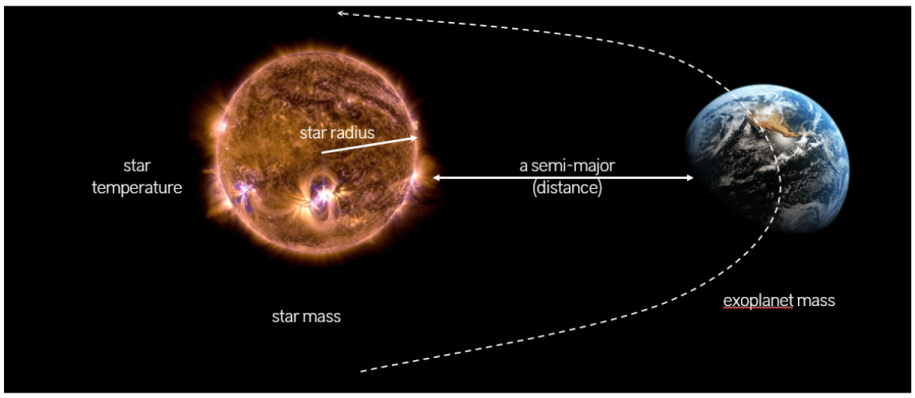


FIGURE 3 – Illustration d'un système étoile–planète et des paramètres auxiliaires.

2.3 Fichiers fournis

— **spectra.npy** : spectres du jeu d'entraînement ;
— **auxiliary.csv** : données auxiliaires d'entraînement ;
— **spectra_test.npy** : spectres du jeu de test ;
— **auxiliary_test.csv** : données auxiliaires du jeu de test ;
— **targets_train.csv** : labels : présence d'eau et de nuages.
Le jeu d'entraînement comporte **3000 planètes**, et le jeu de test **1032 planètes**.
Les étiquettes associées sont binaires :

$$\text{eau} \in \{0, 1\}, \qquad \text{nuages} \in \{0, 1\}.$$

3 Statistiques descriptives

Cette section a pour objectif d'explorer les données spectrales et auxiliaires afin de mieux comprendre leur structure, leur variabilité et leur capacité à discriminer la présence d'eau et de nuages dans les atmosphères exoplanétaires.

3.1 Distribution des classes

Avant la phase de modélisation, une analyse de la distribution des classes cibles a été réalisée afin de vérifier l'équilibre du jeu de données. Les deux variables à prédire sont binaires : la présence d'eau et la présence de nuages dans l'atmosphère des exoplanètes.

3.1.1 Présence d'eau

La Figure 4 présente la distribution des classes pour la variable *eau*. On observe une répartition équilibrée entre les deux classes : autant de spectres correspondent à des atmosphères contenant de l'eau qu'à des atmosphères sans eau.

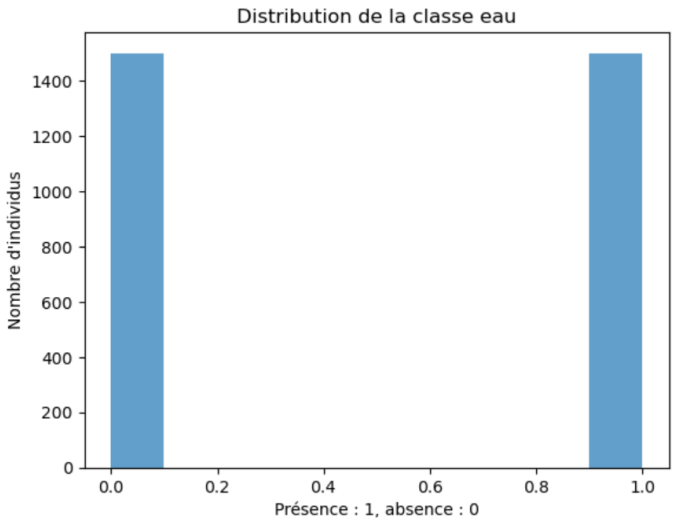


FIGURE 4 – Distribution des classes pour la présence d'eau.

3.1.2 Présence de nuages

De manière similaire, la Figure 5 montre la distribution des classes pour la variable *nuages*. Là encore, les deux classes sont représentées de façon équilibrée, avec autant d'exoplanètes nuageuses que non nuageuses.

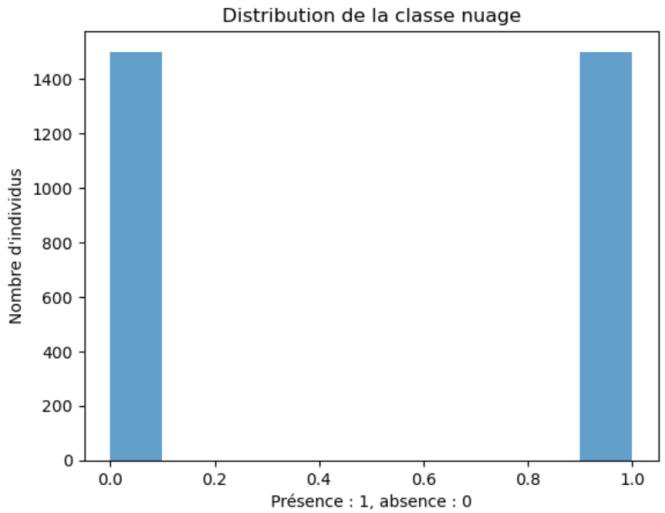


FIGURE 5 – Distribution des classes pour la présence de nuages.

L'équilibre observé entre les deux classes pour chacune des variables cibles constitue un point favorable pour l'apprentissage automatique. En effet, l'absence de déséquilibre de classes limite les biais lors de l'entraînement des modèles et permet l'utilisation de métriques d'évaluation classiques, telles que l'accuracy, la précision ou le rappel, sans nécessiter d'ajustement particulier. Cela facilite également la comparaison des performances entre les différents modèles étudiés.

3.2 Analyse de la variabilité des spectres

Afin d'évaluer l'échelle et la diversité des spectres de transit, un échantillon aléatoire de 100 spectres a été visualisé. La Figure 6 montre la profondeur de transit en fonction de l'indice spectral.

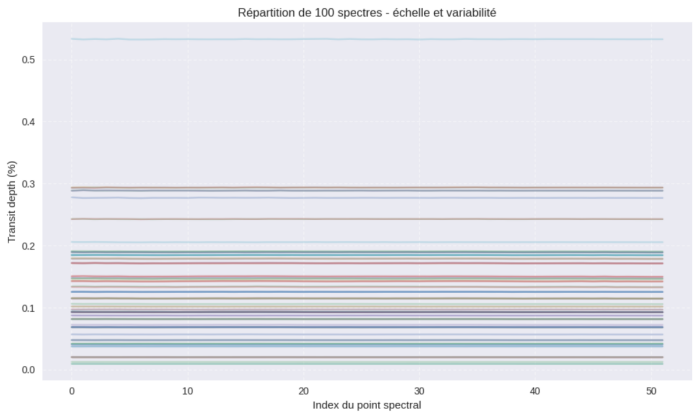


FIGURE 6 – Répartition de 100 spectres de transit tirés aléatoirement.

On observe une variabilité significative des profondeurs de transit selon les longueurs d'onde, suggérant la présence de signatures atmosphériques distinctes. Cette diversité est essentielle pour permettre à un modèle d'apprentissage automatique d'identifier des motifs discriminants.

3.3 Réduction de dimension des spectres par ACP

Les spectres, composés de 52 longueurs d'onde, constituent un espace de grande dimension. Une Analyse en Composantes Principales (ACP) a été appliquée après centrage des spectres afin de projeter les données dans un espace bidimensionnel tout en conservant un maximum de variance.

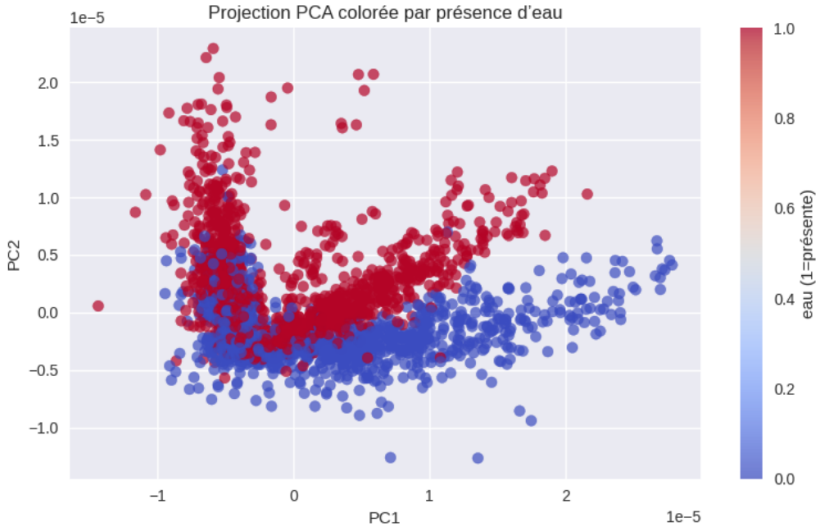


FIGURE 7 – Projection ACP des spectres, colorée par la présence d'eau.

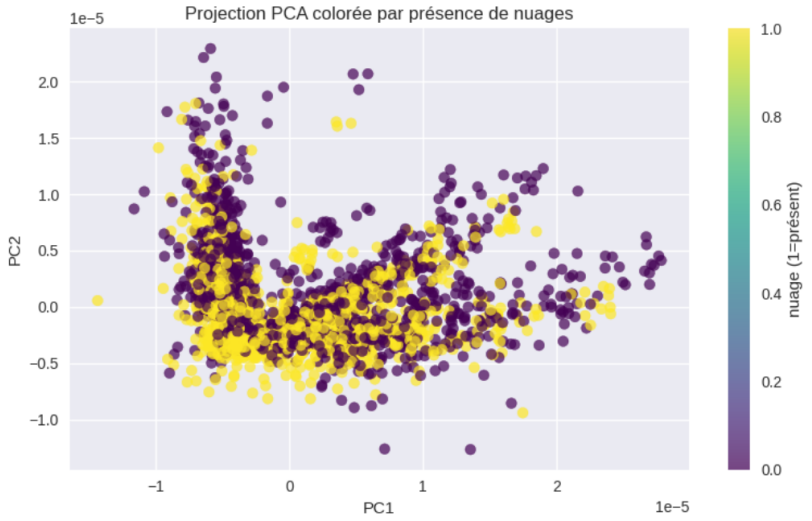


FIGURE 8 – Projection ACP des spectres, colorée par la présence de nuages.

Dans la projection ACP colorée par la présence d'eau, on observe une séparation relativement marquée entre les classes avec et sans eau. Les observations associées à la présence

d'eau se projettent majoritairement dans la partie supérieure du plan factoriel, tandis que celles correspondant à l'absence d'eau se situent plutôt dans la partie inférieure. Toutefois, un chevauchement notable subsiste au centre de l'espace, traduisant une structure complexe des données et une séparation imparfaite dans l'espace linéaire défini par les premières composantes principales.

En revanche, dans la projection ACP colorée par la présence de nuages, la séparation entre les classes avec et sans nuages apparaît beaucoup moins marquée. Les deux classes présentent un fort recouvrement, suggérant que la variabilité capturée par les premières composantes principales ne permet pas de discriminer efficacement la présence de nuages.

De manière générale, les projections ACP mettent en évidence un recouvrement important entre les classes, en particulier pour la discrimination des nuages. Cela indique que la séparation entre les classes eau et nuages n'est pas triviale dans l'espace linéaire des deux premières composantes principales. Ces observations justifient le recours à des modèles non linéaires, tels que des méthodes d'apprentissage avancées ou des réseaux de neurones, pour la phase de modélisation et de classification.

3.4 Analyse des vecteurs propres de l'ACP

Les vecteurs propres issus de l'ACP (également appelés *loadings*) décrivent la contribution de chaque longueur d'onde à la construction des composantes principales. Ils permettent ainsi d'identifier les régions spectrales responsables de la variance observée dans les données.

La Figure 9 présente les vecteurs propres associés aux deux premières composantes principales, calculés sur les 52 longueurs d'onde du spectre.

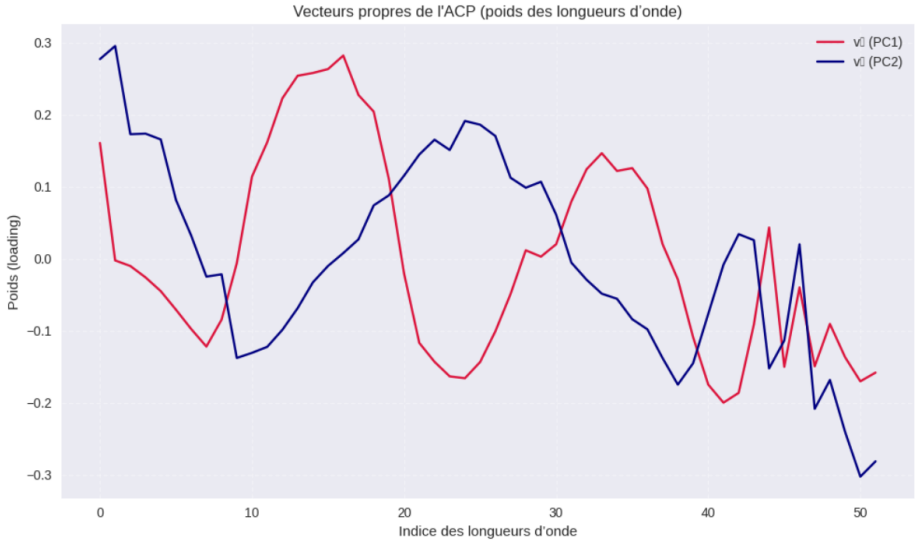


FIGURE 9 – Vecteurs propres associés aux deux premières composantes principales. Chaque coefficient représente le poids d'une longueur d'onde dans la composante considérée.

D'après la décomposition d'un individu X_i dans la base des vecteurs propres :

$$X_i = \bar{X} + \sum_k \langle X_i - \bar{X}, v_k \rangle v_k,$$

les composantes principales sont construites comme des combinaisons linéaires des longueurs d'onde pondérées par les coefficients des vecteurs propres v_k. Ainsi, des coefficients

proches de zéro sur certaines longueurs d'onde indiquent que ces régions spectrales contribuent peu à la variance capturée par la composante considérée.

Dans la figure, les coefficients des vecteurs propres oscillent majoritairement autour de zéro, avec quelques variations modérées mais sans pics fortement dominants. Cela suggère qu'aucune zone spectrale ne se distingue nettement comme étant prépondérante dans la construction des deux premières composantes principales. La variance expliquée est donc répartie sur l'ensemble du spectre, ce qui est cohérent avec la nature continue et corrélée des signatures spectrales atmosphériques.

Par conséquent, bien que certaines longueurs d'onde contribuent davantage que d'autres, l'information utile n'est pas localisée dans un sous-ensemble restreint de bandes. Cela limite la capacité des premières composantes principales à fournir, à elles seules, une séparation nette des classes, et renforce l'intérêt d'approches de modélisation capables de capturer des relations non linéaires ou des interactions plus complexes entre les longueurs d'onde.

3.5 Analyse exploratoire des variables auxiliaires

Les cinq paramètres astrophysiques auxiliaires ont été standardisés, puis projetés dans un espace bidimensionnel à l'aide d'une ACP, afin d'étudier leur structure et leur lien avec les classes cibles.

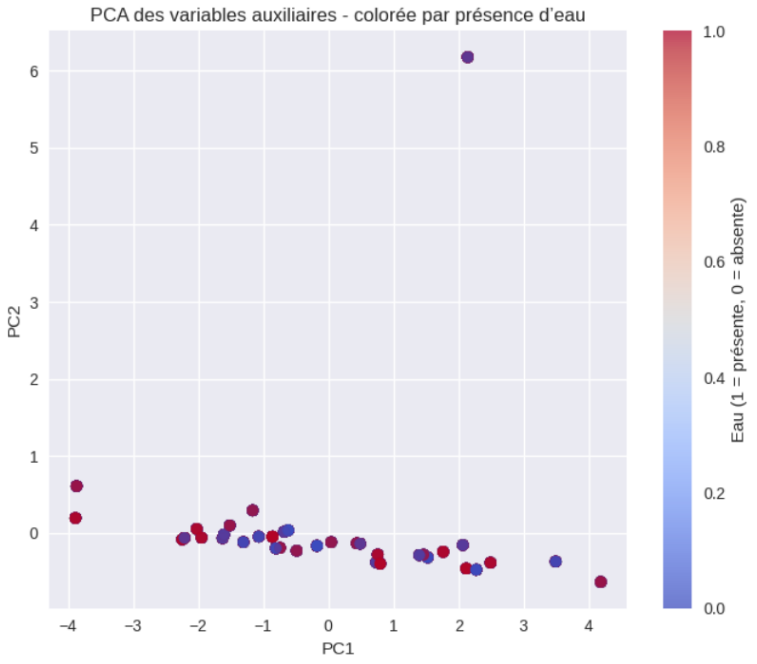


FIGURE 10 – ACP des variables auxiliaires, colorée par la présence d'eau.

La projection ne montre pas de séparation nette entre les classes, mais suggère des corrélations possibles entre certains paramètres astrophysiques et la présence d'eau.

3.6 Relations entre paramètres astrophysiques

Des pairplots ont été utilisés afin d'explorer les relations bivariées entre les paramètres auxiliaires, colorées selon les classes cibles.

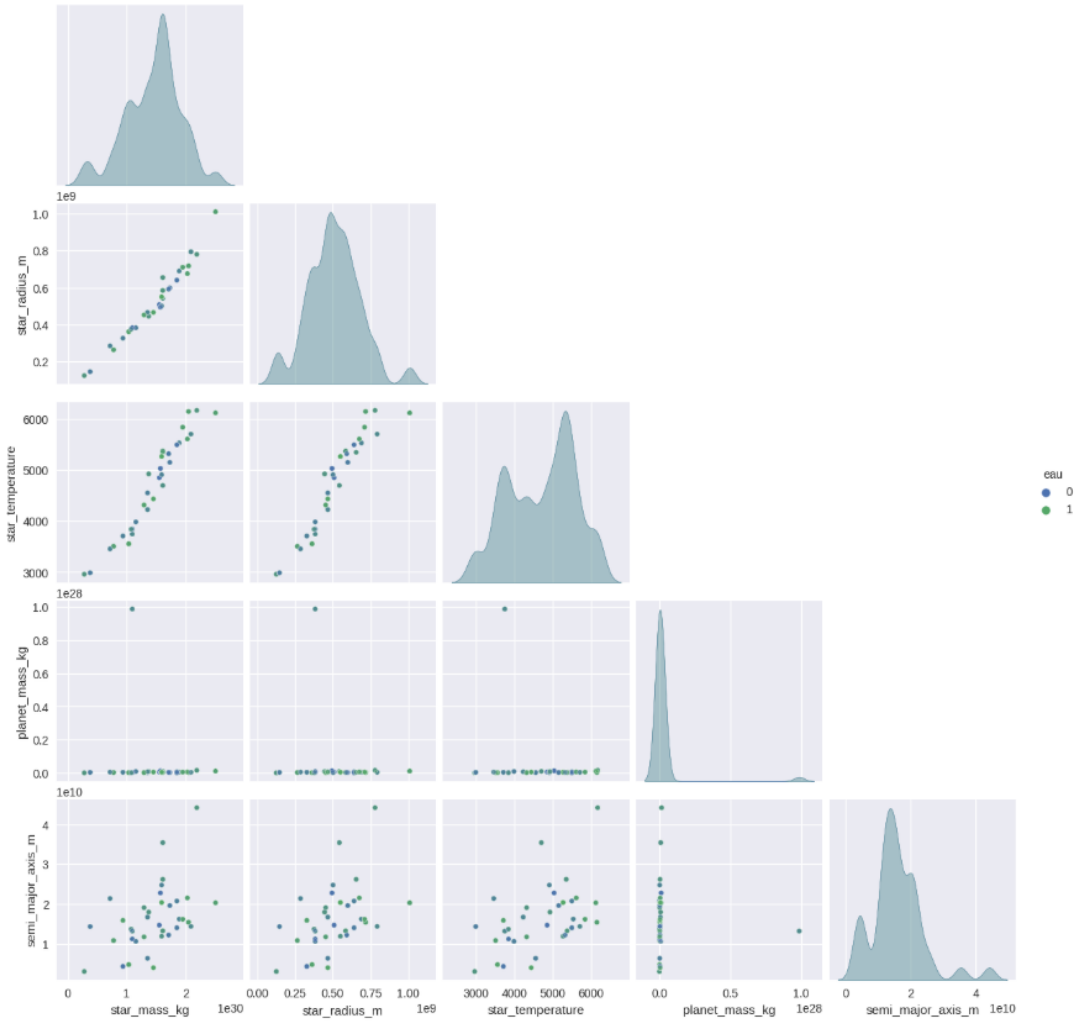


FIGURE 11 – Relations entre variables auxiliaires, colorées par la présence d'eau.

Les visualisations mettent en évidence des relations physiques cohérentes entre certains paramètres astrophysiques, notamment entre les variables stellaires ainsi qu'entre les paramètres planétaires. En revanche, aucune séparation nette n'apparaît entre les classes associées à la présence d'eau ou de nuages dans les différents plans bivariés.

Ces observations suggèrent que, prises isolément ou deux à deux, les variables auxiliaires ne sont pas suffisantes pour discriminer les classes cibles. Elles constituent néanmoins une information complémentaire susceptible d'améliorer les performances des modèles lorsqu'elles sont combinées aux données spectrales dans un cadre d'apprentissage supervisé.

3.7 Synthèse de l'analyse descriptive

L'analyse descriptive met en évidence une forte redondance entre les variables auxiliaires, ainsi qu'une absence de séparation linéaire claire entre les classes associées à la présence d'eau ou de nuages. De même, les spectres présentent une variabilité principalement globale, sans signature spectrale locale fortement marquée.

Ces résultats suggèrent que la détection des propriétés atmosphériques repose sur des interactions complexes et non linéaires entre longueurs d'onde et paramètres physiques,

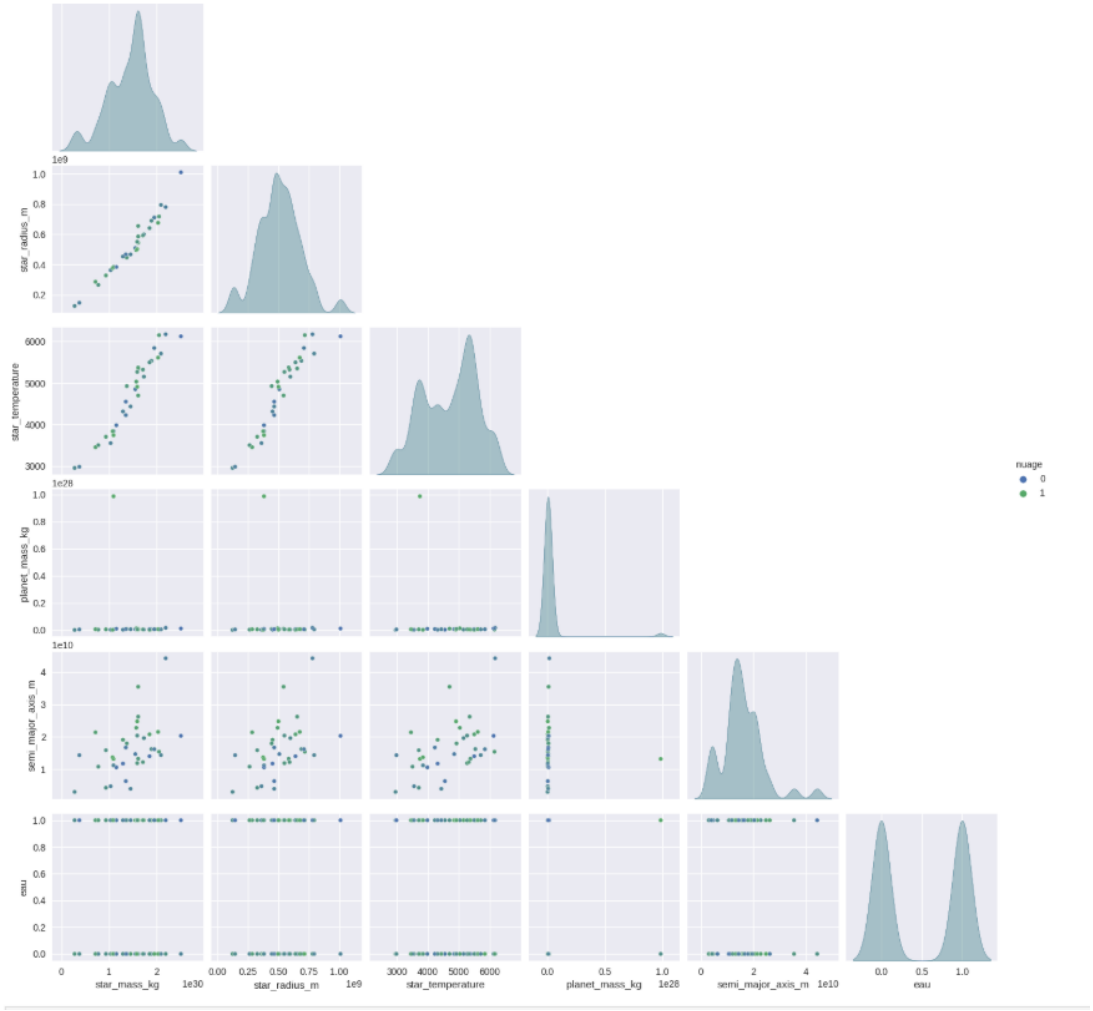


FIGURE 12 – Relations entre variables auxiliaires, colorées par la présence de nuages.

motivant l'utilisation de modèles d'apprentissage supervisé plus expressifs dans la suite de l'étude.

4 Prétraitement et normalisation

4.1 Transformation des données auxiliaires

Avant l'entraînement des modèles, les données auxiliaires ont été transformées afin d'améliorer leur interprétabilité physique et de garantir une cohérence d'échelle entre les différentes variables.

4.1.1 Changement d'unités et mise à l'échelle physique

Les paramètres astrophysiques ont été exprimés en unités normalisées, couramment utilisées en astrophysique :

— la masse de la planète est exprimée en unités de masse jovienne ;
— le rayon théorique de la planète est exprimé en unités de rayon jovien ;
— la masse de l'étoile est exprimée en unités de masse solaire ;

— le rayon de l'étoile est exprimé en unités de rayon solaire.

Les constantes utilisées sont :

$$R_{\text{Jup}} = 6.9911 \times 10^7 \text{ m}, \quad M_{\text{Jup}} = 1.898 \times 10^{27} \text{ kg},$$

$$R_\odot = 6.9634 \times 10^8 \text{ m}, \quad M_\odot = 1.9891 \times 10^{30} \text{ kg}.$$

4.1.2 Calcul du rayon théorique de la planète

En l'absence du rayon planétaire parmi les variables fournies, un rayon théorique a été estimé à partir de la masse de la planète et de sa gravité de surface, supposée constante.

À partir de la relation entre la gravité de surface, la masse et le rayon d'une planète :

$$g = \frac{GM_p}{R_p^2},$$

le rayon planétaire peut être déduit comme :

$$R_p = \sqrt{\frac{GM_p}{g}},$$

où G est la constante universelle de gravitation.

Dans ce travail, la gravité de surface a été fixée à une valeur constante $g = 20$ m·s^{-2} pour toutes les planètes, permettant d'obtenir une estimation homogène du rayon planétaire. Le rayon calculé est ensuite exprimé en unités de rayon jovien.

4.1.3 Sélection des variables finales

Après transformation, les variables auxiliaires retenues pour la modélisation sont les suivantes :

— rayon de l'étoile hôte ($R_\star/R_\odot$) ;
— température de l'étoile hôte ;
— masse de la planète (M_p/M_{Jup}) ;
— demi-grand axe de l'orbite ;
— masse de l'étoile ($M_\star/M_\odot$) ;
— rayon théorique de la planète (R_p/R_{Jup}).

Les mêmes transformations ont été appliquées strictement à l'identique au jeu de données d'entraînement et au jeu de test, afin d'éviter toute fuite d'information (*data leakage*).

4.2 Normalisation des données

Les données spectrales et les données auxiliaires présentent des caractéristiques très différentes, tant en termes d'échelle que de distribution. Les spectres correspondent à des séries continues de profondeurs de transit, tandis que les variables auxiliaires décrivent des paramètres astrophysiques hétérogènes (masses, rayons, températures, distances orbitales).

Il a donc été nécessaire d'appliquer des stratégies de normalisation distinctes pour chaque type de données afin d'améliorer la stabilité de l'apprentissage et les performances des modèles.

4.2.1 Normalisation des données spectrales

Plusieurs méthodes de normalisation et de transformation des spectres ont été testées :
— normalisation par la moyenne ;
— normalisation par le maximum ;
— standardisation (*z-score*) ;
— normalisation robuste ;
— transformation fréquentielle par FFT ;
— dérivées discrètes d'ordre 1 et 2 ;
— filtrage de Savitzky–Golay ;
— normalisation par la norme L_2.

Les résultats montrent que les normalisations par la moyenne et par la norme L_2 sont les plus performantes pour les données spectrales. La normalisation L_2, en particulier, permet de conserver la forme relative du spectre tout en supprimant l'effet d'échelle globale, ce qui améliore la robustesse des modèles.

4.2.2 Normalisation des données auxiliaires

Pour les données auxiliaires, les méthodes suivantes ont été évaluées :
— normalisation par la moyenne ;
— normalisation par le maximum ;
— standardisation ;
— normalisation robuste.

Les meilleures performances ont été obtenues avec la standardisation (*StandardScaler*) et, dans certains cas, avec la normalisation par la moyenne. La combinaison offrant les meilleurs résultats globaux est :
— normalisation L_2 pour les spectres ;
— standardisation pour les variables auxiliaires.

Cette combinaison est celle retenue pour le modèle final, car elle conduit au meilleur F1-score sur la plateforme Kaggle.

5 Comparaison et choix des modèles

5.1 Comparaison des modèles de classification

Plusieurs modèles de classification supervisée ont été entraînés afin de prédire la présence d'eau et de nuages dans l'atmosphère des exoplanètes. Les performances sont évaluées à l'aide de l'accuracy et du F1-score, ce dernier étant privilégié car il prend en compte à la fois la précision et le rappel mais aussi c'est la métrique utilisé par la plateforme kaggle.

5.1.1 Random Forest

Le modèle *Random Forest* est une méthode d'apprentissage par ensemble reposant sur l'agrégation de plusieurs arbres de décision. Soit un jeu de données d'apprentissage

$$\mathcal{D} = \{(X_i, y_i)\}_{i=1}^{n},$$

où $X_i \in \mathbb{R}^p$ représente le vecteur des variables explicatives (spectrales et auxiliaires) et $y_i \in \{0, 1\}$ la variable cible.

Chaque arbre T_b, $b = 1, \ldots, B$, est entraîné sur un échantillon bootstrap $\mathcal{D}_b$ obtenu par tirage aléatoire avec remise depuis $\mathcal{D}$. À chaque nœud de l'arbre, une partition est recherchée parmi un sous-ensemble aléatoire de $m < p$ variables.

Pour un arbre donné, la prédiction est définie par :

$$\hat{y}^{(b)}(X) = T_b(X).$$

La prédiction finale du Random Forest est obtenue par agrégation des prédictions individuelles :

$$\hat{y}_{RF}(X) = \text{mode}\left(\hat{y}^{(1)}(X), \ldots, \hat{y}^{(B)}(X)\right),$$

ou, dans une formulation probabiliste,

$$\hat{P}_{RF}(y = 1 \mid X) = \frac{1}{B} \sum_{b=1}^{B} \hat{P}^{(b)}(y = 1 \mid X).$$

Le Random Forest permet ainsi de réduire la variance du modèle par moyennage, tout en conservant la capacité des arbres de décision à modéliser des relations non linéaires complexes entre les variables.

Le modèle Random Forest constitue une première approche non linéaire robuste, capable de gérer des interactions complexes entre les variables.

Les performances obtenues sont les suivantes :

— F1-score eau : 0.9610 ;
— F1-score nuages : 0.8544 ;
— F1-score moyen : 0.9077.

Ce modèle offre d'excellents résultats pour la détection de l'eau, mais des performances plus limitées pour la détection des nuages.

5.1.2 Gradient Boosting

Le Gradient Boosting repose sur une construction séquentielle d'un modèle additif composé d'apprenants faibles. Dans le cadre de la classification binaire, le modèle est formulé comme :

$$F_M(X) = \sum_{m=1}^{M} \gamma_m h_m(X),$$

où h_m désigne un arbre de décision peu profond et γ_m son poids associé.

L'apprentissage vise à minimiser une fonction de perte $\mathcal{L}$, généralement la log-vraisemblance négative pour la classification :

$$\mathcal{L}(y, F(X)) = -\left[y \log \sigma(F(X)) + (1 - y) \log(1 - \sigma(F(X)))\right],$$

avec σ la fonction sigmoïde.

À l'itération m, l'arbre h_m est ajusté sur le gradient négatif de la perte, calculé pour chaque observation :

$$r_i^{(m)} = - \left. \frac{\partial \mathcal{L}(y_i, F(X_i))}{\partial F(X_i)} \right|_{F = F_{m-1}}.$$

Le modèle est ensuite mis à jour selon :

$$F_m(X) = F_{m-1}(X) + \eta\, \gamma_m h_m(X),$$

où $\eta \in (0, 1]$ est le taux d'apprentissage (*learning rate*).

La probabilité prédite appartient alors à :

$$\hat{P}(y = 1 \mid X) = \sigma(F_M(X)).$$

Cette approche permet une réduction progressive du biais du modèle et une focalisation de l'apprentissage sur les observations difficiles à prédire.

Le modèle de Gradient Boosting permet de construire un classifieur plus fin en combinant plusieurs arbres faibles de manière séquentielle.

Les performances obtenues sont :

— F1-score eau : 0.9599 ;

— F1-score nuages : 0.9282 ;

— F1-score moyen : 0.9440.

Ce modèle obtient les meilleures performances globales parmi les modèles testés, en particulier pour la détection des nuages.

5.1.3 Gradient Boosting avec réduction de dimension

Une réduction de dimension par Analyse en Composantes Principales (ACP) a également été testée avant l'apprentissage du modèle de Gradient Boosting. Le nombre de composantes retenues est de 36.

Les performances obtenues sont :

— F1-score eau : 0.9444 ;

— F1-score nuages : 0.8390 ;

— F1-score moyen : 0.8917.

Les résultats montrent une dégradation des performances par rapport au modèle sans ACP, indiquant que certaines composantes spectrales discriminantes ont été perdues lors de la réduction de dimension.

5.2 Analyse des performances des modèles

Pour l'ensemble des modèles testés, les performances associées à la détection des nuages sont systématiquement inférieures à celles obtenues pour la détection de l'eau.

Cette différence ne semble pas provenir d'un déséquilibre du jeu de données, les distributions des variables auxiliaires étant similaires entre les classes.

Les analyses exploratoires, notamment l'ACP des spectres, montrent que la présence d'eau génère des signatures spectrales plus distinctes, avec une séparation relativement nette entre les classes. À l'inverse, les signatures associées aux nuages apparaissent plus faibles et plus mélangées dans l'espace des composantes principales.

Ces observations sont cohérentes avec l'interprétation physique du problème : les nuages produisent des effets spectraux plus diffus et fortement dépendants des conditions atmosphériques, ce qui rend leur détection plus complexe.

5.3 Choix du modèle final

Après comparaison de plusieurs algorithmes (Random Forest, Gradient Boosting), le modèle de Gradient Boosting a été retenu pour la suite du projet.

Ce choix s'explique par :

— ses performances supérieures en F1-score moyen ;

— une meilleure détection des nuages par rapport aux autres modèles ;
— sa capacité à modéliser des relations non linéaires complexes.

6 Stratégie d'optimisation et validation

6.1 Validation croisée et séparation des classes

Une validation croisée à 10 plis (*10-fold cross-validation*) a été mise en place afin d'obtenir une estimation robuste des performances du modèle.

Les résultats ont montré que les performances diffèrent significativement entre les deux classes cibles (eau et nuages). Afin de tenir compte de cette asymétrie, les prédictions ont été traitées séparément pour chaque classe au sein d'un cadre de classification multi-sorties.

6.2 Optimisation des seuils de décision

Par défaut, les classifieurs binaires utilisent un seuil de décision fixé à 0.5. Cependant, ce choix n'est pas nécessairement optimal pour maximiser le F1-score.

Pour chaque pli de la validation croisée, un seuil optimal a été recherché indépendamment pour la prédiction de l'eau et des nuages, en maximisant le F1-score sur un ensemble de seuils candidats.

Les seuils optimaux obtenus sont ensuite moyennés sur les 10 plis afin de définir un seuil final pour chaque classe. Cette approche a permis d'améliorer significativement les performances globales du modèle.

6.3 Résultats du modèle optimisé

Après application de la normalisation optimale, de la validation croisée à 10 plis et de l'optimisation des seuils de décision, les performances moyennes obtenues sur les données d'entraînement sont :

— Accuracy eau : 0.984 ;
— Accuracy nuages : 0.976 ;
— F1-score moyen : 0.980.

Ces résultats témoignent de l'efficacité de la stratégie d'optimisation mise en place, chaque étape contribuant à une amélioration progressive des performances dans le cadre de la validation croisée.

Toutefois, un écart systématique est observé entre les performances obtenues en validation croisée et celles mesurées sur le jeu de test Kaggle, le F1-score Kaggle restant inférieur à celui estimé lors des tests internes. Cela suggère une capacité de généralisation perfectible du modèle, malgré les précautions méthodologiques adoptées.

6.4 Modèle final et soumission Kaggle

Le modèle final est entraîné sur l'ensemble du jeu d'entraînement complet, en utilisant les paramètres optimisés et les normalisations sélectionnées. Une calibration des probabilités par méthode isotone est appliquée afin d'améliorer la qualité des probabilités prédites.

Les seuils de décision finaux, déterminés par moyennage des seuils optimaux issus de la validation croisée, sont ensuite utilisés pour générer les prédictions sur le jeu de test.

Le modèle obtient les performances suivantes sur la plateforme Kaggle :

— score public : 0.958 ;

— score privé : 0.959.

Bien que ces scores soient inférieurs aux performances observées en validation croisée, ils restent compétitifs dans le cadre du défi. À titre de comparaison, le meilleur score observé sur le classement Kaggle est de l'ordre de 0.986. L'écart observé indique que le modèle conserve une marge d'amélioration, notamment en termes de généralisation.

6.5 Bilan méthodologique

L'amélioration progressive des performances repose sur une succession d'étapes clés :

— choix de normalisations adaptées à la nature des données spectrales et auxiliaires ;

— sélection d'un modèle performant de type Gradient Boosting ;

— mise en place d'une validation croisée rigoureuse à 10 plis ;

— optimisation indépendante des seuils de décision pour chaque classe ;

— calibration des probabilités et entraînement final sur l'ensemble des données.

Malgré ces optimisations, un écart persistant entre les performances internes et celles obtenues sur Kaggle suggère un phénomène de sur-ajustement modéré ou une différence de distribution entre les données d'entraînement et de test. Le temps limité n'a pas permis d'explorer exhaustivement l'ensemble des pistes potentielles pour réduire cet écart.

7 Conclusion

Ce projet s'inscrit dans le contexte de la mission ARIEL et du Défi IA 2025, dont l'objectif est la caractérisation atmosphérique des exoplanètes à partir de spectres de transit simulés.

Une analyse approfondie des données spectrales et auxiliaires a été menée, suivie de la conception et de l'optimisation de plusieurs modèles d'apprentissage automatique. Le modèle final, basé sur le Gradient Boosting, combine une normalisation adaptée, une validation croisée rigoureuse, une optimisation des seuils de décision et une calibration des probabilités.

Les performances obtenues en validation croisée sont élevées, avec un F1-score moyen proche de 0.98. Sur le jeu de test Kaggle, le modèle atteint un score public de 0.958 et un score privé de 0.959, indiquant une bonne capacité de généralisation, bien qu'inférieure aux performances internes et au meilleur score du classement.

Les principales limites identifiées concernent la généralisation du modèle et la difficulté intrinsèque à détecter la présence de nuages, dont les signatures spectrales sont plus faibles et plus variables que celles de l'eau.

Parmi les pistes d'amélioration envisageables figurent l'exploration de modèles plus complexes, tels que les réseaux neuronaux profonds ou les architectures convolutionnelles, l'intégration plus fine de l'information d'incertitude spectrale, ainsi que des stratégies avancées de régularisation et d'ensemblage. Par ailleurs, la mise en œuvre de techniques d'augmentation des données, adaptées aux spectres (ajout de bruit réaliste, perturbations contrôlées des longueurs d'onde ou des amplitudes), pourrait permettre d'enrichir l'espace d'apprentissage et d'améliorer la capacité de généralisation du modèle, en particulier dans un contexte de jeu de données limité.