Quant-GAN

Génération profonde de séries temporelles financières

YNMTT

Université de Bordeaux

January 30, 2026

Présentation

université de BORDEAUX

- Thème : génération synthétique de séries temporelles financières
- Basé sur l'article *Quant GANs* (Wiese et al.)

Objectif : comprendre comment les réseaux de neurones peuvent simuler le comportement des marchés financiers.

Problématique

- Les marchés financiers sont bruités et complexes

Problématique

- Les marchés financiers sont bruités et complexes
- Fortes dépendances temporelles (clusters de volatilité, effet de levier)

Problématique

- Les marchés financiers sont bruités et complexes
- Fortes dépendances temporelles (clusters de volatilité, effet de levier)
- Volatilité variable dans le temps (hétéroscédasticité)

Problématique

- Les marchés financiers sont bruités et complexes
- Fortes dépendances temporelles (clusters de volatilité, effet de levier)
- Volatilité variable dans le temps (hétéroscédasticité)

Question centrale :
Comment générer des séries temporelles financières réalistes sans hypothèses probabilistes fortes ?

Description des données

- Données issues de marchés financiers réels

Description des données

- Données issues de marchés financiers réels
- Prix transformés en **log-rendements**

Description des données

- Données issues de marchés financiers réels
- Prix transformés en **log-rendements**
- Séries découpées en fenêtres temporelles pour le discriminateur

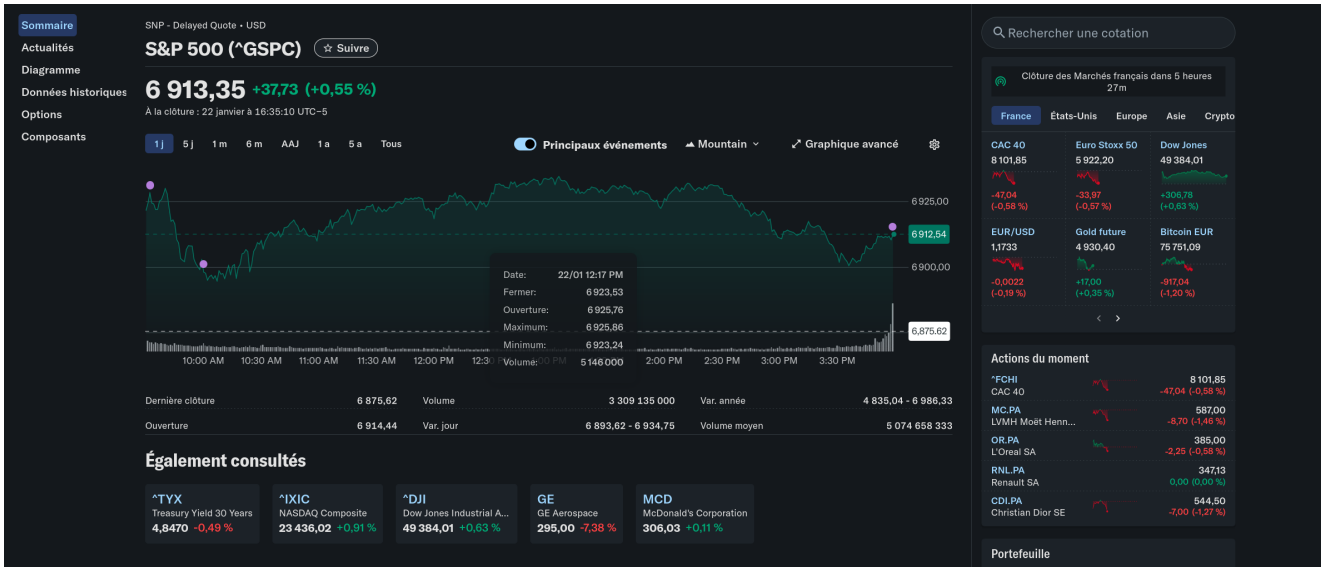
Description des données

- Données issues de marchés financiers réels
- Prix transformés en **log-rendements**
- Séries découpées en fenêtres temporelles pour le discriminateur

Description des données

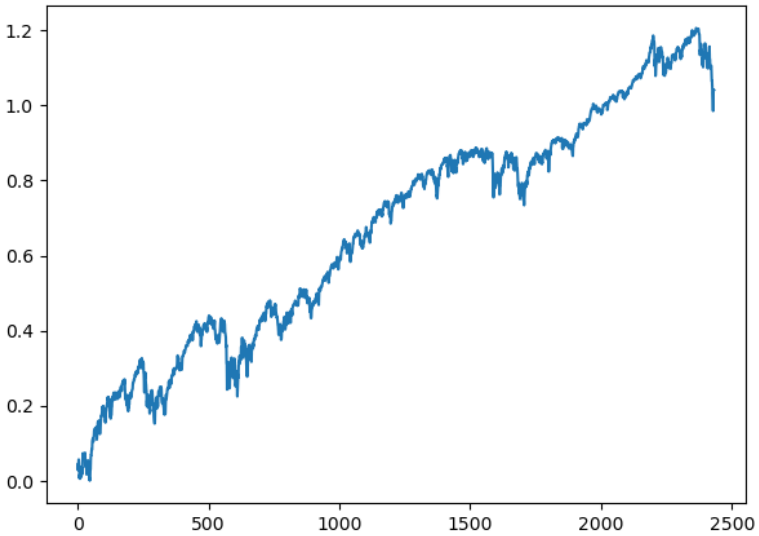
- Données issues de marchés financiers réels
- Prix transformés en **log-rendements**
- Séries découpées en fenêtres temporelles pour le discriminateur

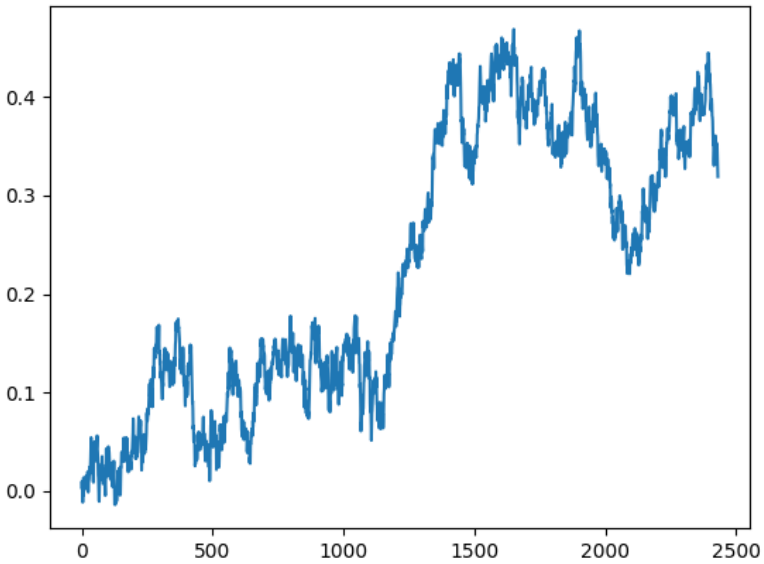
Les log-rendements améliorent la stationnarité et l'interprétation financière.



Source : Yahoo Finance, indice S&P 500

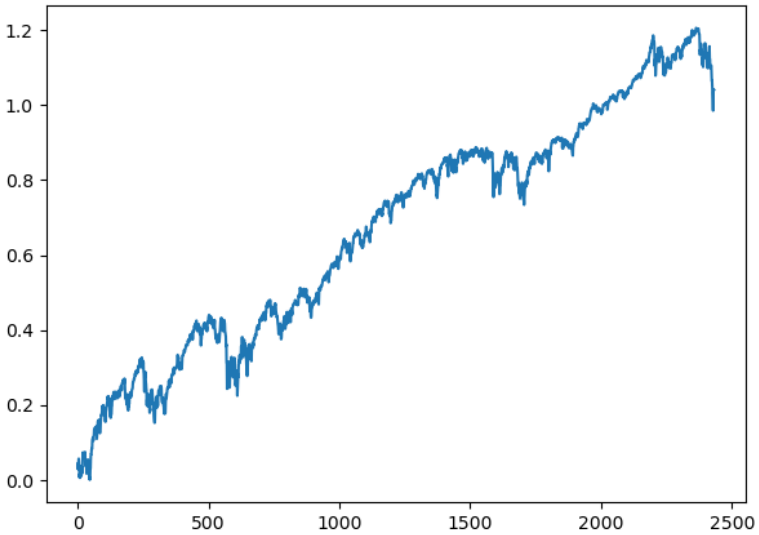
Comparaison



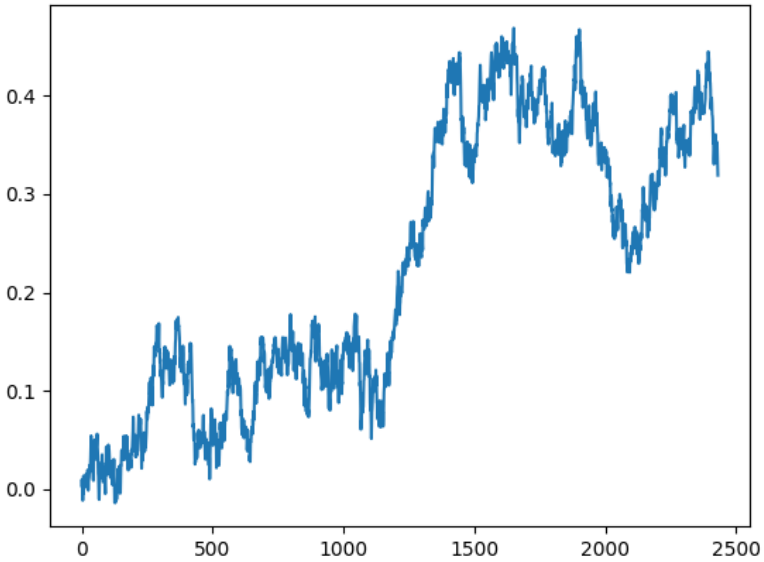


Lesquelles vous semblent les plus réalistes ?

Comparaison



Données réelles



Données générées

Pouvez-vous faire la différence ?

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Objectifs du projet

Au cours de ce travail, nous cherchons à :

Objectifs du projet

Au cours de ce travail, nous cherchons à :

- Expliquer le principe d'un **GAN** (Réseau Adversarial Génératif) à partir des définitions et algorithmes de l'article

Objectifs du projet

Au cours de ce travail, nous cherchons à :

- Expliquer le principe d'un **GAN** (Réseau Adversarial Génératif) à partir des définitions et algorithmes de l'article
- Justifier l'intérêt des **TCN** pour les données financières : avantages et limites face aux **LSTM**, rôle de la **dilatation** D et de la **taille du champ réceptif (RFS)**

Objectifs du projet

Au cours de ce travail, nous cherchons à :

- Expliquer le principe d'un **GAN** (Réseau Adversarial Génératif) à partir des définitions et algorithmes de l'article
- Justifier l'intérêt des **TCN** pour les données financières : avantages et limites face aux **LSTM**, rôle de la **dilatation** D et de la **taille du champ réceptif (RFS)**
- Comprendre et reproduire les expériences numériques : **Figures A.3, A.4, A.11, A.12** et hyperparamètres $N_Z, N_X, T^{(g)}, T^{(d)}$

Objectifs du projet

Au cours de ce travail, nous cherchons à :

- Expliquer le principe d'un **GAN** (Réseau Adversarial Génératif) à partir des définitions et algorithmes de l'article
- Justifier l'intérêt des **TCN** pour les données financières : avantages et limites face aux **LSTM**, rôle de la **dilatation** D et de la **taille du champ réceptif (RFS)**
- Comprendre et reproduire les expériences numériques : **Figures A.3, A.4, A.11, A.12** et hyperparamètres $N_Z, N_X, T^{(g)}, T^{(d)}$
- Tester le modèle sur le S&P 500 puis sur d'autres actifs (via `yfinance`) et analyser les **instabilités d'entraînement**

Objectifs du projet

Au cours de ce travail, nous cherchons à :

- Expliquer le principe d'un **GAN** (Réseau Adversarial Génératif) à partir des définitions et algorithmes de l'article
- Justifier l'intérêt des **TCN** pour les données financières : avantages et limites face aux **LSTM**, rôle de la **dilatation** D et de la **taille du champ réceptif (RFS)**
- Comprendre et reproduire les expériences numériques : **Figures A.3, A.4, A.11, A.12** et hyperparamètres $N_Z, N_X, T^{(g)}, T^{(d)}$
- Tester le modèle sur le S&P 500 puis sur d'autres actifs (via `yfinance`) et analyser les **instabilités d'entraînement**
- Comparer Quant-GAN aux modèles classiques (Black–Scholes, ARMA, GARCH) via une **évaluation discriminante** et les **métriques du papier**

Objectifs du projet

Au cours de ce travail, nous cherchons à :

- Expliquer le principe d'un **GAN** (Réseau Adversarial Génératif) à partir des définitions et algorithmes de l'article
- Justifier l'intérêt des **TCN** pour les données financières : avantages et limites face aux **LSTM**, rôle de la **dilatation** D et de la **taille du champ réceptif (RFS)**
- Comprendre et reproduire les expériences numériques : **Figures A.3, A.4, A.11, A.12** et hyperparamètres $N_Z, N_X, T^{(g)}, T^{(d)}$
- Tester le modèle sur le S&P 500 puis sur d'autres actifs (via `yfinance`) et analyser les **instabilités d'entraînement**
- Comparer Quant-GAN aux modèles classiques (Black–Scholes, ARMA, GARCH) via une **évaluation discriminante** et les **métriques du papier**
- Discuter l'extension **multivariée** (plusieurs actifs et dépendances croisées)

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Log-rendement

$$X_n = \ln\left(\frac{S_n}{S_{n-1}}\right)$$

Où S_n est le prix au jour n.

Log-rendement

$$X_n = \ln\left(\frac{S_n}{S_{n-1}}\right)$$

Où S_n est le prix au jour n.

Pourquoi ?

- meilleure stationnarité (approx.) et interprétation directe (rendement)
- standard en économétrie/finance pour comparer distributions et dépendances

Black & Scholes

Black & Scholes (log-rendement i.i.d., Gaussiens)

$$X_t = \mu + \sigma \varepsilon_t$$

Black & Scholes

Black & Scholes (log-rendement i.i.d., Gaussiens)

$$X_t = \mu + \sigma \varepsilon_t$$

- X_t: log-rendement μ: rendement moyen
- σ: volatilité (risque) ε_t: bruit (souvent $\mathcal{N}(0,1)$)

Black & Scholes

Black & Scholes (log-rendement i.i.d., Gaussiens)

$$X_t = \mu + \sigma \varepsilon_t$$

- X_t: log-rendement μ: rendement moyen
- σ: volatilité (risque) ε_t: bruit (souvent $\mathcal{N}(0,1)$)

Limites

- queues épaisses, volatilité en grappes, effet de levier

ARMA

$$X_n = \mu + a_1 X_{n-1} + \cdots + a_p X_{n-p} + \sigma \left(\varepsilon_n + b_1 \varepsilon_{n-1} + \cdots + b_q \varepsilon_{n-q} \right)$$

ARMA

$$X_n = \mu + a_1 X_{n-1} + \cdots + a_p X_{n-p} + \sigma\left(\varepsilon_n + b_1 \varepsilon_{n-1} + \cdots + b_q \varepsilon_{n-q}\right)$$

- X_n: log-rendement au jour n
- a_j et b_i: paramètres AR / MA
- μ : rendement moyen σ : échelle

ARMA

$$X_n = \mu + a_1 X_{n-1} + \cdots + a_p X_{n-p} + \sigma\left(\varepsilon_n + b_1 \varepsilon_{n-1} + \cdots + b_q \varepsilon_{n-q}\right)$$

- X_n: log-rendement au jour n
- a_j et b_i: paramètres AR / MA
- μ : rendement moyen σ : échelle

Limites : modèle linéaire $\Rightarrow$ capture surtout l'autocorrélation linéaire, moins la volatilité.

GARCH

$$X_n = \mu + \sigma_n \varepsilon_n,$$
$$\sigma_n^2 = a_0 + a_1 \sigma_{n-1}^2 + \cdots + a_p \sigma_{n-p}^2 + b_1 (\sigma_{n-1} \varepsilon_{n-1})^2 + \cdots + b_q (\sigma_{n-q} \varepsilon_{n-q})^2$$

GARCH

$$X_n = \mu + \sigma_n \varepsilon_n,$$
$$\sigma_n^2 = a_0 + a_1 \sigma_{n-1}^2 + \cdots + a_p \sigma_{n-p}^2 + b_1 (\sigma_{n-1}\varepsilon_{n-1})^2 + \cdots + b_q (\sigma_{n-q}\varepsilon_{n-q})^2$$

- conçu pour modéliser les **clusters de volatilité / risques** via la dynamique de σ_n^2

GARCH

$$X_n = \mu + \sigma_n \varepsilon_n,$$
$$\sigma_n^2 = a_0 + a_1 \sigma_{n-1}^2 + \cdots + a_p \sigma_{n-p}^2 + b_1 (\sigma_{n-1}\varepsilon_{n-1})^2 + \cdots + b_q (\sigma_{n-q}\varepsilon_{n-q})^2$$

- conçu pour modéliser les **clusters de volatilité / risques** via la dynamique de σ_n^2

Limites : distribution souvent gaussienne conditionnelle $\Rightarrow$ queues/peak imparfaits, leverage difficile.

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Qu'est-ce qu'un GAN?

Qu'est-ce qu'un GAN?

Generative Adversarial Networks

Qu'est-ce qu'un GAN?

Generative Adversarial Networks $\Leftrightarrow$ Réseaux Adversaires Génératifs (RAG)

Qu'est-ce qu'un GAN?

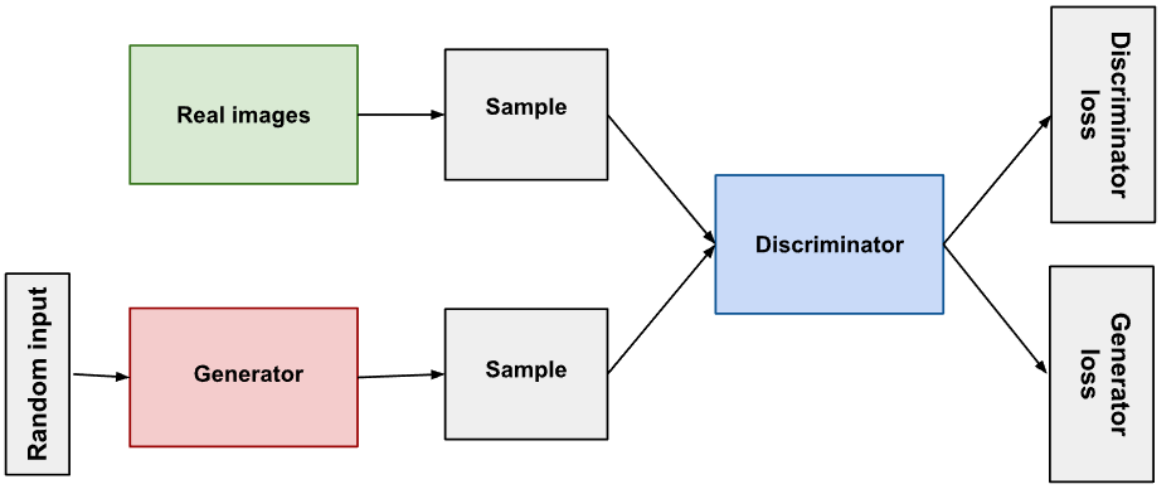
Generative Adversarial Networks $\Leftrightarrow$ Réseaux Adversaires Génératifs (RAG)

- Deux réseaux de neurones:
  - Générateur (G): génère des valeurs modélisées
  - Discriminant (D): classifie le vrai du faux
- Entraînés conjointement (Jeu à somme nulle)

Qu'est-ce qu'un GAN?

Generative Adversarial Networks $\Leftrightarrow$ Réseaux Adversaires Génératifs (RAG)

- Deux réseaux de neurones:
  - Générateur (G): génère des valeurs modélisées
  - Discriminant (D): classifie le vrai du faux
- Entraînés conjointement (Jeu à somme nulle)



Source: developers.google GAN

Idée clé: générer des données identiques aux valeurs réelles.

Principe d'un RAG (GAN) d'après l'article

Cadre : $Z \in \mathbb{R}^{N_z}$ (bruit), $X \in \mathbb{R}^{N_x}$ (donnée).
Générateur $g_\theta : \mathbb{R}^{N_z} \to \mathbb{R}^{N_x}$, discriminateur $d_\eta : \mathbb{R}^{N_x} \to [0, 1]$.

Principe d'un RAG (GAN) d'après l'article

Cadre : $Z \in \mathbb{R}^{N_z}$ (bruit), $X \in \mathbb{R}^{N_x}$ (donnée).
Générateur $g_\theta : \mathbb{R}^{N_z} \to \mathbb{R}^{N_x}$, discriminateur $d_\eta : \mathbb{R}^{N_x} \to [0,1]$.

Objectif min-max :

$$\min_\theta \max_\eta \ \mathcal{L}(\theta, \eta) = \mathbb{E}[\log d_\eta(X)] + \mathbb{E}[\log(1 - d_\eta(g_\theta(Z)))].$$

Principe d'un RAG (GAN) d'après l'article

Cadre : $Z \in \mathbb{R}^{N_Z}$ (bruit), $X \in \mathbb{R}^{N_X}$ (donnée).
Générateur $g_\theta : \mathbb{R}^{N_Z} \to \mathbb{R}^{N_X}$, discriminateur $d_\eta : \mathbb{R}^{N_X} \to [0,1]$.

Objectif min-max :

$$\min_\theta \max_\eta \ \mathcal{L}(\theta, \eta) = \mathbb{E}[\log d_\eta(X)] + \mathbb{E}[\log(1 - d_\eta(g_\theta(Z)))].$$

Entraînement (Algorithme GAN) :

- plusieurs mises à jour de D (ascendant) pour approcher d_η,
- puis une mise à jour de G (descendant) pour tromper D,
- alternance jusqu'à équilibre (en pratique instable).

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Pourquoi un Quant-GAN?

- Les GANs standards sont conçus pour générer des images
- Les données des marchés sont temporelles (dépendence + régimes)
- Quant-GAN utilise des **Réseaux de Convolutions Temporelles**, (TCN)

Pourquoi un Quant-GAN?

- Les GANs standards sont conçus pour générer des images
- Les données des marchés sont temporelles (dépendence + régimes)
- Quant-GAN utilise des **Réseaux de Convolutions Temporelles**, (TCN)

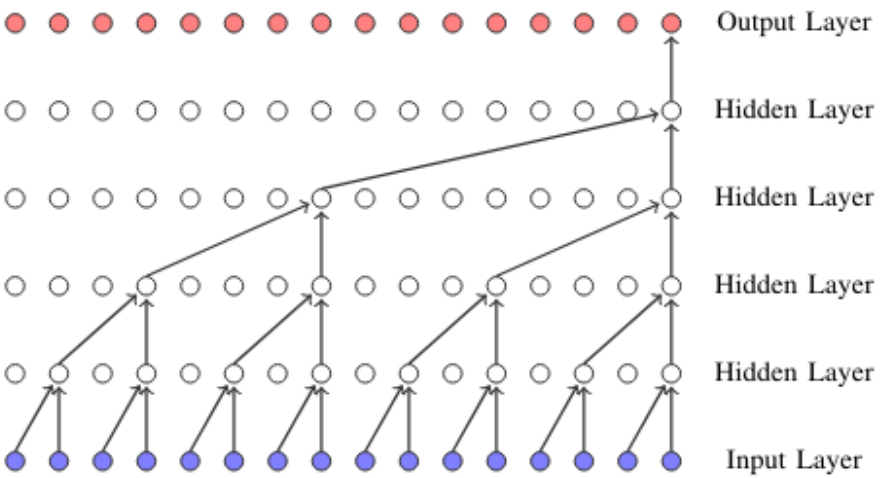


Figure 6: Vanilla TCN with 4 hidden layers, kernel size $K = 2$ and dilation factor $D = 2$ (cf. van den Oord et al. (2016)).

Pourquoi un Quant-GAN?

- Les GANs standards sont conçus pour générer des images
- Les données des marchés sont temporelles (dépendence + régimes)
- Quant-GAN utilise des **Réseaux de Convolutions Temporelles**, (TCN)

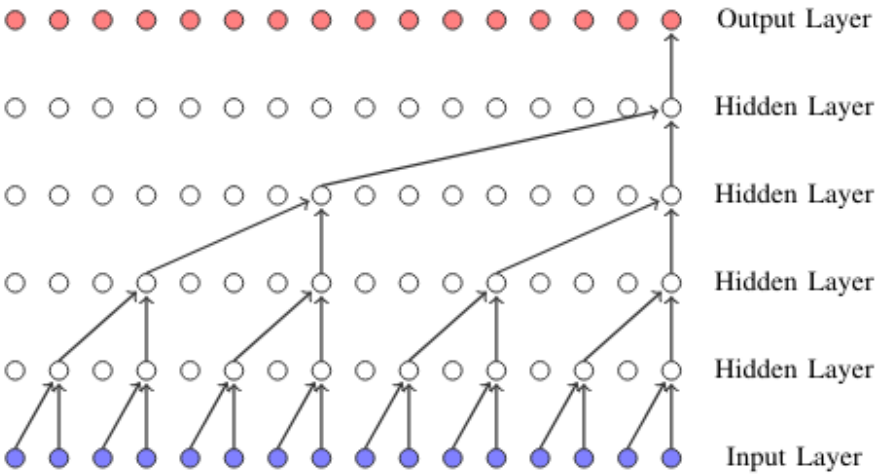


Figure 6: Vanilla TCN with 4 hidden layers, kernel size $K = 2$ and dilation factor $D = 2$ (cf. van den Oord et al. (2016)).

Dans l'article:

- Adaptés aux dépendances de grandes portées (clusters de risques)
- Peuvents êtres entraînés en parallèles et compatible avec la

RAG pour séries temporelles : génération comme processus

Dans l'article, la génération est formulée comme un **processus** :

$$\tilde{X}_{t,\theta} = g_\theta\left(Z_{t-(T^{(g)}-1):t}\right),$$

où g_θ est un **TCN** de **champ récépteur** $T^{(g)}$.

RAG pour séries temporelles : génération comme processus

Dans l'article, la génération est formulée comme un **processus** :

$$\tilde{X}_{t,\theta} = g_\theta\left(Z_{t-(T^{(g)}-1):t}\right),$$

où g_θ est un **TCN** de **champ récépteur** $T^{(g)}$.

Fenêtrage côté discriminant :

- le discriminant voit des **fenêtres** de longueur $T^{(d)}$ (rolling window, stride 1),
- $T^{(d)}$ est choisi en cohérence avec le champ récépteur du TCN discriminant,
- ce fenêtrage facilite l'apprentissage sur une série longue (un grand nombre d'exemples).

SVNN: un générateur Quant-GAN

Le générateur principal proposé (SVNN) suit une décomposition “volatilité + innovations” :

$$R_{t,\theta} = \sigma_{t,\theta}\, \varepsilon_{t,\theta} + \mu_{t,\theta}.$$

- $(\sigma_{t,\theta}, \mu_{t,\theta})$ produits par un **TCN** à partir de $Z_{t-T^{(g)}:t-1}$
- $\varepsilon_{t,\theta}$ produit par un petit réseau à partir de Z_t
- N_X = dimension (univariée si N_X=1, multivariée si N_X>1)

Definition LSTM

Un LSTM (*Long Short-Term Memory*) est un RNN qui traite une séquence pas à pas. Il maintient :

- un **état caché** h_t (ce que le modèle retient pour prédire),
- un **état mémoire** c_t (mémoire longue),

mis à jour via des **portes** (*forget*, *input*, *output*) qui contrôlent quoi oublier / ajouter / exposer.

TCN et LSTM pour les séries temporelles financières (motivation)

Pourquoi TCN (plutôt que LSTM) ?

- **Moins de problèmes de gradients** que les RNN (vanishing/exploding).
- **Parallélisable** $\Rightarrow$ entraînement plus efficace.
- Contrôle explicite de la mémoire via la RFS (choix de $T^{(g)}$, $T^{(d)}$).

Limites :

- mémoire bornée par la RFS (il faut dimensionner correctement le réseau),

Facteur de dilatation D et taille du champ réceptif (RFS)

Dilatation D : convolutions "avec trous" $\Rightarrow$ on espace les points du passé utilisés.
Si $D = 2$, la dilatation double à chaque couche (1,2,4,...), ce qui augmente la mémoire rapidement.

RFS (pour un TCN avec ,taille du kernel K, L couches, $D > 1$) :

$$T^{(f)} = 1 + (K-1)\left(\frac{D^L - 1}{D - 1}\right).$$

grande RFS $\Rightarrow$ dépendances longues (volatility clustering), sans explosion de paramètres.

Hyperparamètres du papier (Pure TCN / S&P 500)

Valeurs demandées :

- $N_X = 1$: log-returns univariés (S&P 500)
- $N_Z = 3$: bruit latent Gaussien (dimension 3)
- $T^{(g)} = 127$: RFS du générateur (Pure TCN)
- $T^{(d)} = 127$: même RFS côté discriminateur (TCN)

Architecture TCN reportée : 7 temporal blocks + skip connections, dilations $1, 1, 2, 4, 8, 16, 32$, kernel 2 (sauf premier bloc kernel 1), hidden dim typique 80.

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Protocole: S&P 500 et stabilité de l'entrainement

Données (papier) : S&P 500 quotidien, *May 2009 – Dec 2018*, 2413 observations.

Point important : instabilité GAN observée dans l'article

- l'entraînement est irrégulier et ne converge pas proprement,
- plusieurs checkpoints sont sauvegardés, et le "meilleur" est choisi via des métriques.

Conséquence pour nos tests :

- plusieurs seeds/runs sont nécessaires,
- même pipeline de preprocessing + sélection par métriques.

Preprocessing pipeline (article)

Avant d'entraîner D (et d'évaluer), l'article applique un pipeline **invertible** :

1. prix $\rightarrow$ **rendements logarithmiques**
2. normalisation (moyenne 0, variance 1)
3. **transformée inverse de Lambert** W ("gaussianiser" les rendements)
4. re-normalisation
5. **fenêtre glissante** de longueur $T^{(d)}$ (pas 1) pour construire le jeu de données du discriminateur

Message clé : Lambert W aide à capturer les **pics + queues** en rendant l'espace d'apprentissage plus proche d'une gaussienne.

Résultats

- Entraîner Quant-GAN sur des données financières réelles (S&P 500 dans l'article)
- Générer des séries temporelles synthétiques (rendements logarithmiques puis trajectoires logarithmiques)
- Comparaison statistique avec les données réelles (distribution + dépendance)

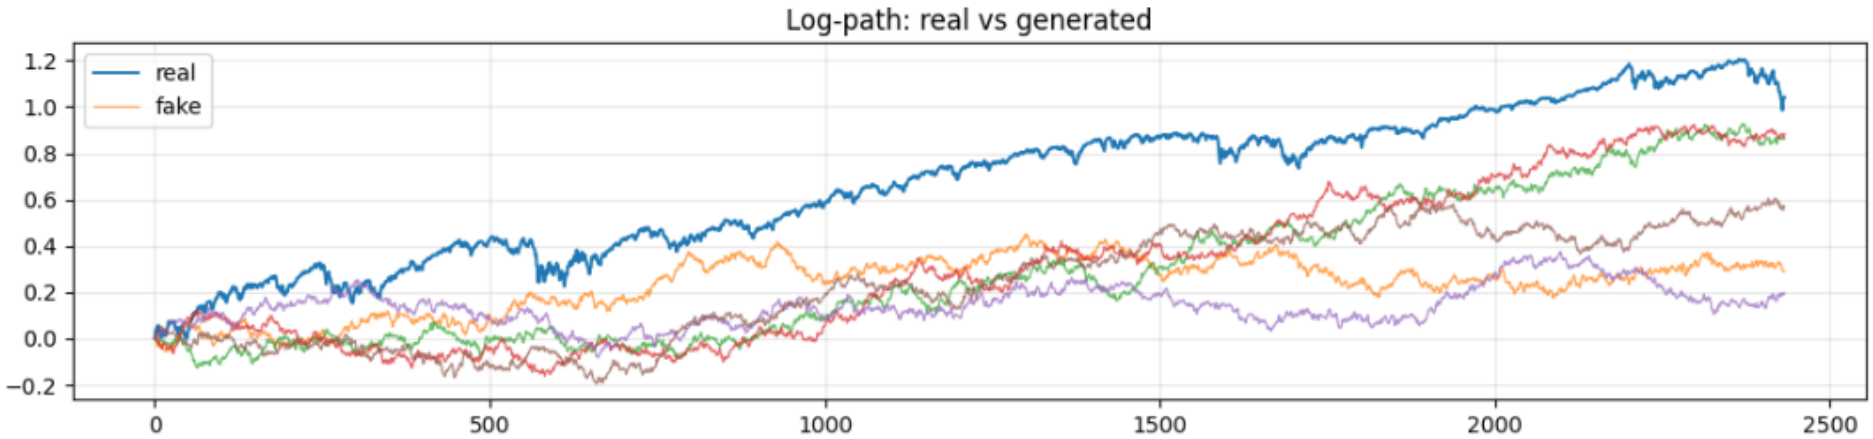
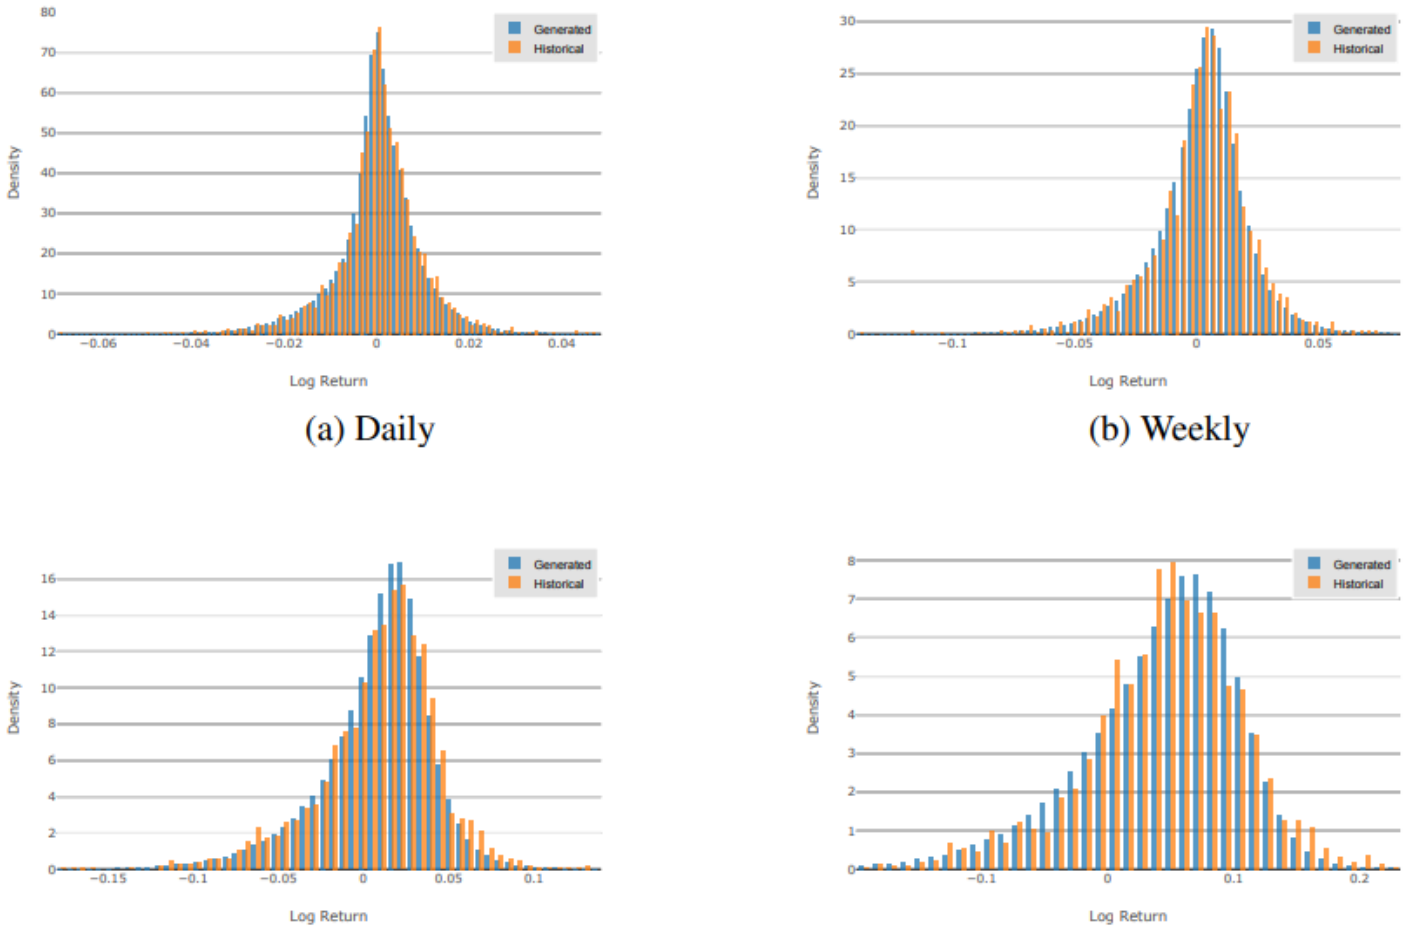


Figure A.3 : distributions à plusieurs horizons du Pure TCN

- histogrammes **daily / weekly / monthly / 100-day** : généré vs historique



(a) Daily

(b) Weekly

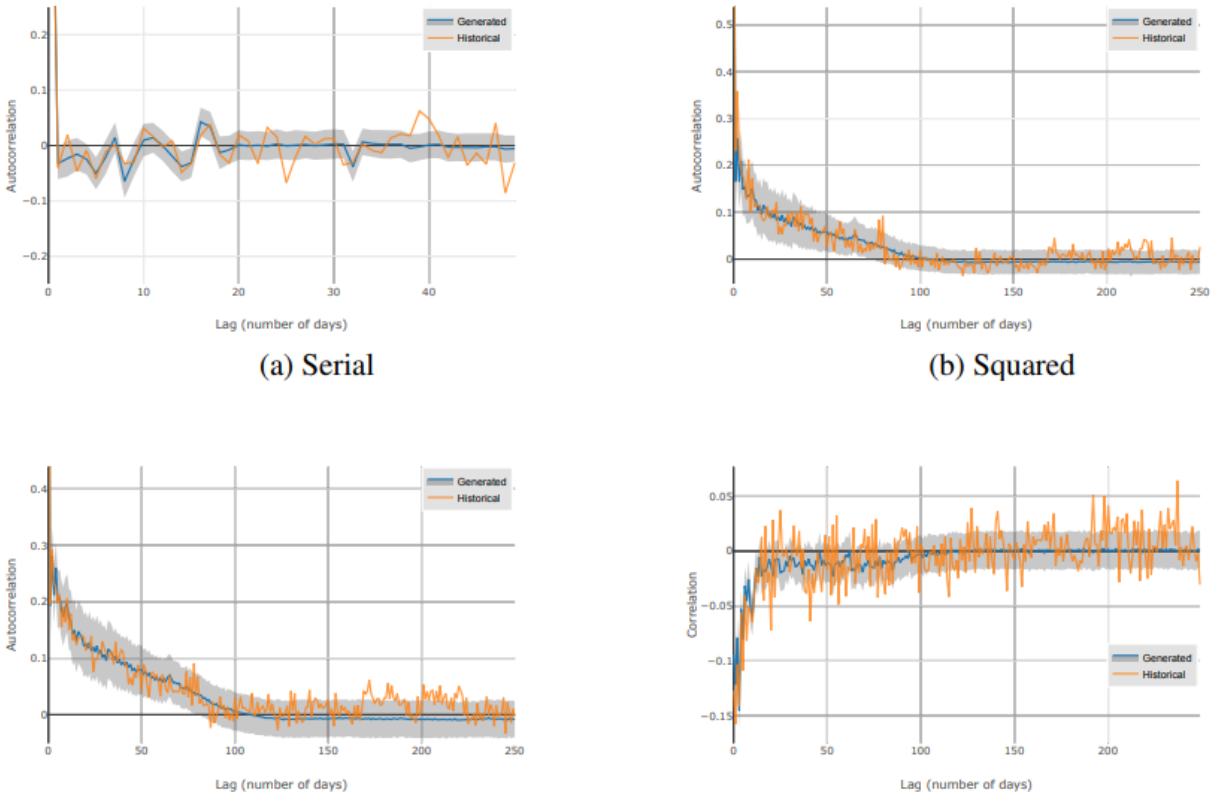
(c) Monthly

(d) 100-day

Figure A.3: Comparison of generated and historical densities of the S&P500.

Figure A.4 : dépendances temporelles du Pure TCN

- autocorrélation (ACF) : chute rapide (souvent proche de 0)
- ACF des rendements **carrés** et **absolus** : décroissance lente (volatility clustering)
- **effect de levier** : corrélation négative (rendements vs volatilité future)



(a) Serial

(b) Squared

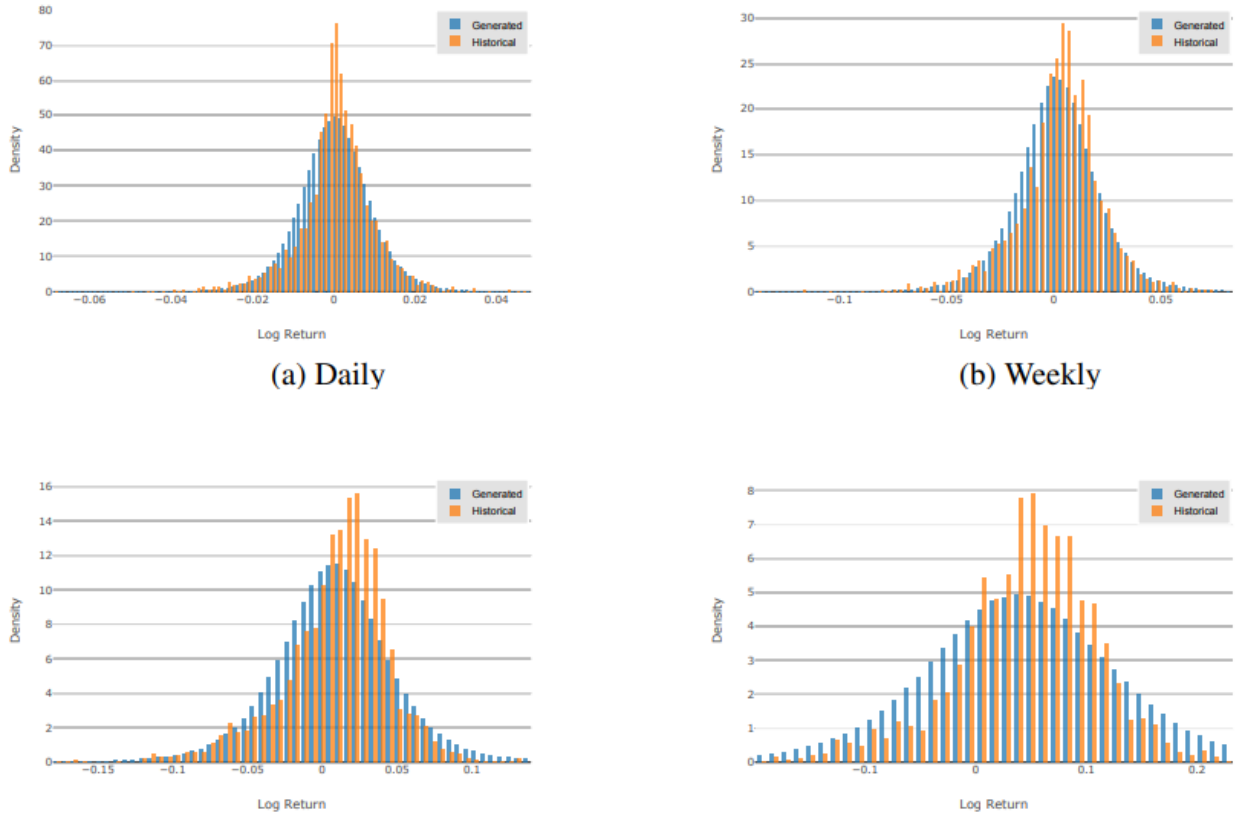
(c) Absolute

(d) Leverage Effect

Figure A.4: Mean autocorrelation function of the absolute, squared and identical log returns and leverage effect.

Figure A.11 : distributions multi-horizons du GARCH

- le GARCH met **trop peu de masse** au pic et dans les queues
- donc : Les histogrammes daily/weekly/monthly/100-day moins bien reproduits



(a) Daily

(b) Weekly

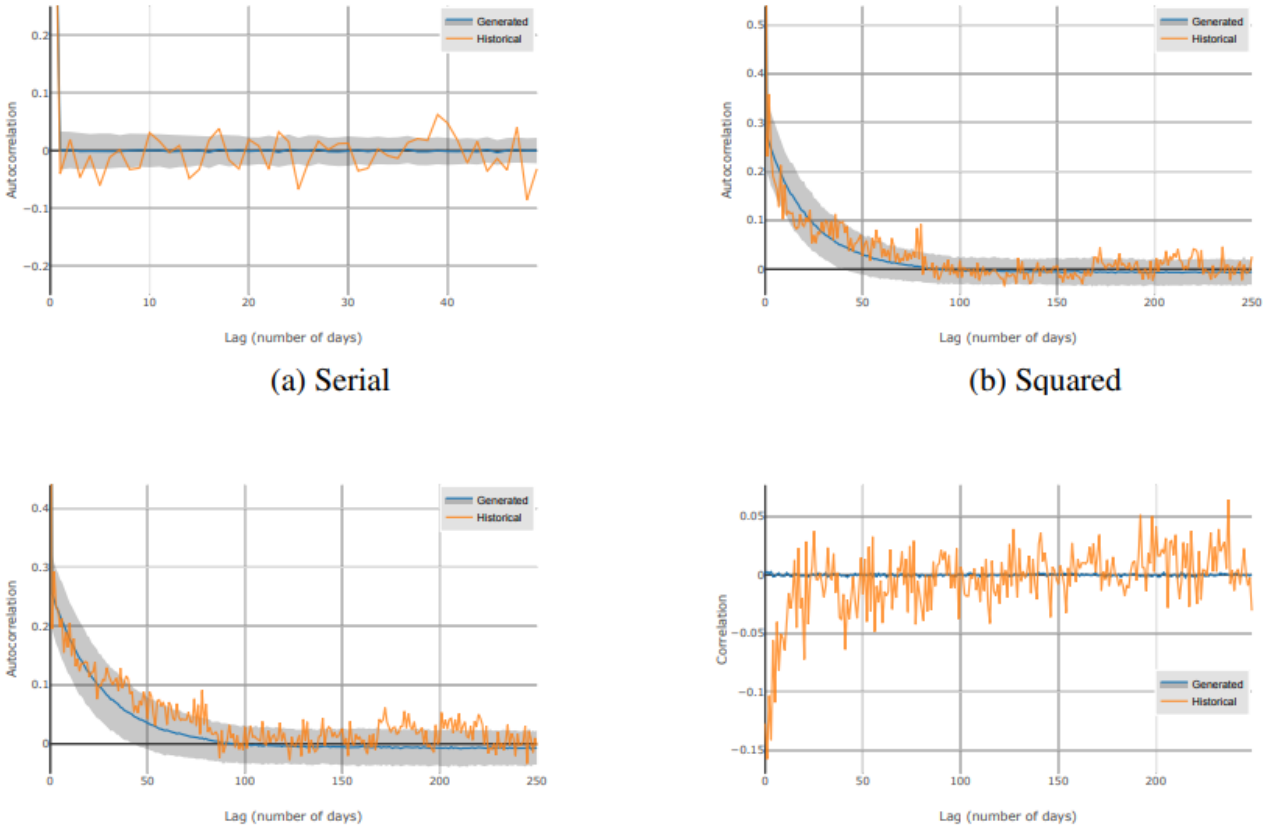
(c) Monthly

(d) 100-day

Figure A.11: Comparison of generated and historical densities of the S&P500.

Figure A.12 : dépendances du GARCH

- ACF (au carré/absolue) est **plutôt bien** capturée (c'est l'objectif du GARCH)
- mais : moins précis que TCN/C-SVNN, et **l'effet de levier n'est pas capturé**



(a) Serial

(b) Squared

(c) Absolute

(d) Leverage Effect

Figure A.12: Mean autocorrelation function of the absolute, squared and identical log returns and leverage effect.

Métriques utilisées dans l'article

Métriques du papier :

- **Distribution** : Earth Mover Distance (EMD/Wasserstein-1), DY metric (Dragulescu-Yakovenko)
- **Dépendance** : scores ACF + score effet de levier (Leverage Effect)

Résultat global :

- le **TCN** est le meilleur sur presque toutes les métriques,
- **GARCH** est le pire globalement (surtout distribution).

On peut **compléter** ces métriques par une évaluation discriminative (accuracy/AUC) comme demandé dans l'énoncé.

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Simulations (Évaluation discriminative)

- Distributions des rendements (et score de réalisme discriminatif)

Quant-GAN reproduit des faits stylisés clés, mais l'entraînement peut laisser des artefacts détectables par un classifieur.

	Accuracy	**AUC**
BlackScholes	0.9424	0.995451
ARMA(1,1)	0.9684	0.995093
QuantGAN(TCN)	0.8736	0.944281
GARCH(1,1)	0.8364	0.914233

Lecture : idéalement ≈ 0.5 (hasard). Plus c'est élevé, plus le discriminateur détecte des artefacts.

Protocole de comparaison : évaluation discriminative (comme requis)

Principe :

- Générer une base synthétique pour chaque modèle (BS, ARMA, GARCH, Quant-GAN).
- Entraîner un classifieur "réel vs synthétique" sur des fenêtres temporelles.
- Comparer Accuracy/AUC (ou log-loss) sur un test set.

Intuition :

- si synthétique $\approx$ réel, le meilleur classifieur ne fait pas mieux que le hasard.

Lien avec l'article :

- l'article utilise EMD/DY/ACF/leverage ; notre score discriminatif est un complément pratique.

Instabilités et astuces de stabilisation (article + pratique)

Ce que dit le papier :

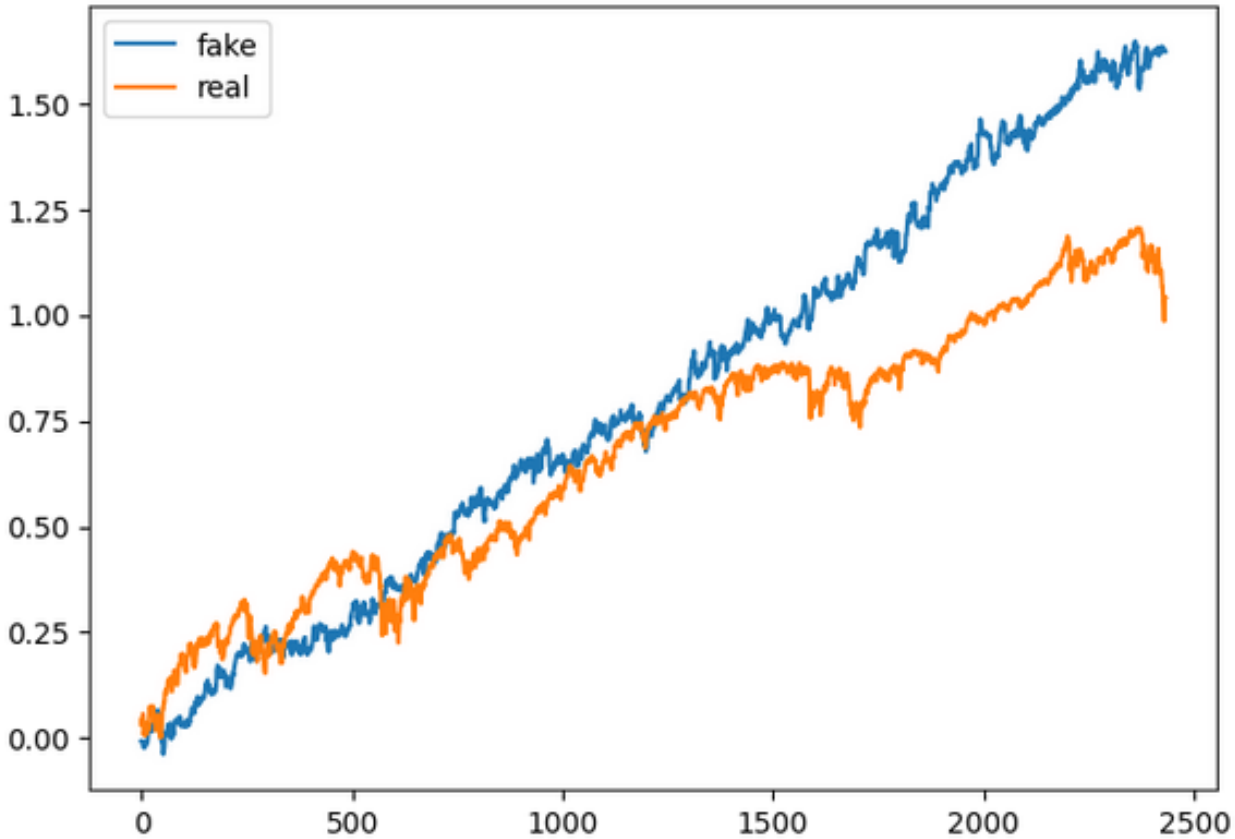
- entraînement GAN **irrégulier** ; sélection du meilleur checkpoint via métriques,
- utilisation d'un **algorithme de stabilité GAN** (Mescheder et al., 2018) pendant l'entraînement.

En pratique (tests yfinance) :

- multiplier les runs (seeds), surveiller collapse/oscillations,
- ajuster ratio updates D/G, learning rates, early stopping,
- variantes possibles : WGAN-GP, gradient penalty, spectral norm.

Améliorations (article)

- Meilleure adéquation des distributions à queues épaisses
- Utilisation de la transformée de Lambert W



La transformée de Lambert ajuste le comportement des queues tout en facilitant l'apprentissage des dépendances.

Transformée de Lambert W : pourquoi elle aide (vue de l'article)

Constat : les retours financiers ont des **queues épaisses**.
Problème : entraîner un modèle à partir d'un bruit gaussien simple devient plus difficile.

Solution du papier :

- appliquer l'**inverse Lambert** W pour rendre les retours plus proches de la realite,

Déroulement

1. Objectifs du projet
2. Modèles financiers classiques
3. GANs
4. Quant-GAN
5. Résultats
6. Nos simulations
7. Conclusion

Conclusion

- L'entraînement des GAN peut être instable (également explicitement rapporté dans l'article) : une sélection de checkpoint est nécessaire
- Quant-GAN (TCN / SVNN) capture mieux les faits stylisés de distribution + dépendance que la baseline GARCH

Questions ouvertes / perspectives :

- Benchmark de générateurs LSTM/RNN (laisse comme travail futur dans l'article)
- Améliorer la modélisation des queues (transformations, losses, priors)
- Extension multivariée : générer plusieurs indices conjointement tout en préservant les dépendances croisées

Multivarié (1/4) : objectif (MarketGANs, 2026)

En $N_X > 1$, on veut une **dynamique jointe** réaliste, pas juste de bonnes marges.

- Génération **jointe** : $R_t \in \mathbb{R}^{N_X}$.
- Cibles : **corrélations** (cross-section), **extrêmes** (tail co-movement), **dépendance temporelle**.
- Biais inductif : **structure factorielle** + architecture **TCN** (mémoire longue).

Huh et al., MarketGANs, arXiv:2601.17773 (2026).

Multivarié (2/4) : générateur factoriel (MarketGAN)

Structure factorielle (génération jointe des N_X actifs) :

$$r_{t+1} = \alpha_t + \beta_t F_{t+1} + \sigma_t \odot \varepsilon_{t+1}, \qquad r_{t+1} \in \mathbb{R}^{N_X}.$$

- $F_{t+1} \in \mathbb{R}^K$: facteurs observés (CAPM / Fama–French).
- $\alpha_t, \beta_t, \sigma_t$: **coefficients variables dans le temps** générés via **TCN**.
- ε_{t+1} : résidu multivarié (capture dépendances restantes).

MarketGAN : coefficients stochastiques + TCN pour la dépendance temporelle.

Multivarié (3/4) : préserver les dépendances (cross + tails)

Au-delà de "tromper D", MarketGAN vise surtout :

- **Corrélation haute dimension** : matcher la matrice de corrélation des actifs.
- **Co-mouvance extrême** : co-exceedances (ex: 1%, 5%) pendant les crashs.
- **Co-volatilité** : dépendances sur $|r|$ ou r^2 (volatility clustering multi-actifs).

$$\mathcal{L}_G = \mathcal{L}_{WGAN\text{-}GP} + \lambda_1 \mathcal{L}_{corr} + \lambda_2 \mathcal{L}_{covol} + \lambda_3 \mathcal{L}_{tail}.$$

Huh et al. : gros gains sur XCorr (corr) et $XCorr^E$ (extrêmes) vs bootstrap factoriel.

Multivarié (4/4) : évaluation (vue portefeuille)

Évaluer **marges + dépendances + impact portefeuille** :

- **Marges** : moments, histos multi-horizons (daily/weekly/monthly), erreurs RMSE/MAE.
- **Dépendances** : $\|\mathrm{Corr}^{real} - \mathrm{Corr}^{syn}\|_F$, co-exceedances (tails).
- **Valeur économique** : covariance $\hat{\Sigma}$ estimée sur données synthétiques $\Rightarrow$ min-var / tangency / VaR–ES.

Résultat : $\hat{\Sigma}$ via MarketGAN améliore les portefeuilles quand l'info facteur est au moins faiblement informative.

Merci pour votre attention !

Questions ?

Référence

Magnus Wiese *et al.*
Quant GANs: Deep Generation of Financial Time Series
Quantitative Finance, 2020