Rapport de Projet

UE M2 Master MAS Transport optimal

Classification supervisée par transport optimal et calcul des poids d'un mélange

Marwa Dades et Soulayman Mahamat Youssouf

Master Mathématiques Appliquées et Statistiques — Université de Bordeaux

Parcours : Modélisation Statistique et Stochastique (MSS)

Tuteur : Jérémie Bigot

16 janvier 2026

Table des matières

1 Introduction **3**

2 Transport optimal exact et classification induite **3**

3 Transport optimal régularisé par Sinkhorn et comparaison des classifications **4**

3.1 Comparaison des coûts de transport et du temps de calcul 4
3.2 Comparaison des estimations de proportions selon les modèles 5
3.3 Impact de la régularisation et analyse des ARI 5
3.4 Comparaison visuelle des classifications 6

4 Conclusion **7**

1 Introduction

La cytométrie en flux est une technologie de biologie expérimentale à haut débit permettant de caractériser un grand nombre de cellules à partir d'un échantillon biologique. Chaque cellule est décrite par plusieurs marqueurs biologiques mesurés par fluorescence, ce qui conduit à des jeux de données de grande dimension. Un enjeu central est l'identification automatique des différentes populations cellulaires, essentielle en immunologie et en médecine.

Dans ce projet, on adopte une approche de *classification supervisée* fondée sur la théorie du transport optimal. L'objectif est d'exploiter un jeu de données source, pour lequel les classes sont connues, afin d'inférer la classification d'un jeu de données cible non labellisé. Cette problématique relève du transfert de connaissances entre distributions.

Le transport optimal offre un cadre mathématique adapté pour comparer des mesures empiriques en tenant compte de la géométrie globale des données. Il permet de construire un plan de transport entre la source et la cible, à partir duquel on peut définir une règle de classification et estimer les proportions des différentes classes dans l'échantillon cible.

Objectifs du projet

Les objectifs de ce projet sont les suivants :

- Résoudre un problème de transport optimal discret entre un jeu de données source labellisé et un jeu de données cible non labellisé ;
- Utiliser le plan de transport obtenu pour attribuer une classe à chaque observation cible par un vote majoritaire pondéré par la masse transportée ;
- Estimer les proportions de chaque classe dans le jeu de données cible ;
- Comparer les résultats obtenus avec le vrai clustering du jeu de données cible ;
- Etudier l'impact de la régularisation entropique sur la qualité de la classification et le temps de calcul.

2 Transport optimal exact et classification induite

Dans cette section, nous présentons le modèle de transport optimal utilisé pour relier les mesures empiriques des jeux de données source et cible, ainsi que les considérations computationnelles liées à sa résolution.

Les jeux de données source et cible sont modélisés par des mesures empiriques discrètes :

$$\hat{\mu}_n = \frac{1}{n}\sum_{i=1}^{n} \delta_{X_i}, \qquad \hat{\nu}_m = \frac{1}{m}\sum_{j=1}^{m} \delta_{Y_j},$$

où $X_i \in \mathbb{R}^d$ sont les observations source labellisées et $Y_j \in \mathbb{R}^d$ les observations cible non labellisées.

Le problème de transport optimal discret consiste à déterminer un plan de transport

$$P^* = \arg\min_{P \in \mathcal{U}(\hat{\mu}_n, \hat{\nu}_m)} \sum_{i=1}^{n}\sum_{j=1}^{m} P_{ij}\, c(X_i, Y_j),$$

avec $c(x, y) = \frac{1}{2}\|x - y\|^2$ le coût quadratique et $\mathcal{U}(\hat{\mu}_n, \hat{\nu}_m)$ l'ensemble des matrices de transport satisfaisant les contraintes de marges.

Ce problème est résolu numériquement à l'aide de l'algorithme du simplexe réseau de la bibliothèque `POT`. En raison de la taille importante des jeux de données, un sous-échantillonnage est souvent utilisé pour les phases de test et de mise au point. Dans ce projet, les résultats présentés sont obtenus en considérant le sous-échantillon égal à l'échantillon complet, c'est-à-dire sans réduction de taille.

Lors de la résolution sur l'échantillon complet, l'algorithme s'est arrêté avant l'optimalité stricte, le nombre maximal d'itérations ayant été atteint. L'augmentation de ce paramètre aurait entraîné un coût computationnel prohibitif. Néanmoins, le plan obtenu constitue une solution quasi-optimale, suffisante pour l'analyse qualitative et la classification supervisée.

À partir du plan de transport P^*, la classification supervisée des observations cible peut être effectuée par vote majoritaire pondéré par la masse transportée :

$$\hat{k}(Y_j) = \arg \max_{k \in \{1,\dots,K\}} \sum_{i \in C_k} P^*_{ij},$$

où C_k désigne la classe k du jeu de données source. Cette approche permet également d'estimer les proportions de chaque classe dans l'échantillon cible.

3 Transport optimal régularisé par Sinkhorn et comparaison des classifications

Pour réduire le coût computationnel et stabiliser la solution, on considère la version régularisée entropiquement :

$$\min_{P \in \mathcal{U}(\hat{\mu}_n, \hat{\nu}_m)} \sum_{i,j} P_{ij}\, c(X_i, Y_j) + \varepsilon \sum_{i,j} P_{ij}(\log P_{ij} - 1),$$

où $\varepsilon > 0$ est le paramètre de régularisation. Le plan régularisé est calculé par l'algorithme itératif de Sinkhorn.

3.1 Comparaison des coûts de transport et du temps de calcul

Le transport optimal exact permet d'obtenir un plan quasi-optimal, avec un coût :

$$\text{Coût OT exact} = 0.0308,$$

pour un temps de calcul total de :

$$\text{Temps de calcul OT exact} = 156.40 \text{ secondes}.$$

Bien que précis, ce calcul est très coûteux en temps, en particulier pour des jeux de données de grande taille. L'algorithme du simplexe réseau peut même s'arrêter avant d'atteindre l'optimalité stricte si le nombre maximal d'itérations est atteint.

En comparaison, la régularisation entropique via l'algorithme de Sinkhorn ($\varepsilon = 0.05$) fournit un plan de transport régularisé avec :

$$\text{Coût Sinkhorn} = 0.1568, \quad \text{Temps de calcul Sinkhorn} = 54.14 \text{ secondes}.$$

Cette comparaison montre clairement que la régularisation permet de réduire fortement le temps de calcul (environ trois fois plus rapide) tout en conservant une qualité de classification comparable au transport exact.

3.2 Comparaison des estimations de proportions selon les modèles

La Figure 1 présente les histogrammes des proportions de classes estimées par le transport optimal exact, par la régularisation entropique via Sinkhorn, et les proportions réelles des classes dans l'échantillon cible.

On observe que la tendance globale est similaire pour les trois modèles : les classes majoritaires et minoritaires sont correctement identifiées, et les proportions estimées restent proches des valeurs réelles. Cependant, certaines incohérences apparaissent pour quelques classes minoritaires, où le plan de transport régularisé ou même exact peut sous- ou surestimer légèrement la proportion.

Ces différences reflètent les limites numériques et la dispersion induite par la régularisation entropique. Néanmoins, la régularisation permet de conserver une estimation des proportions fiable tout en offrant un gain significatif en termes de temps de calcul.

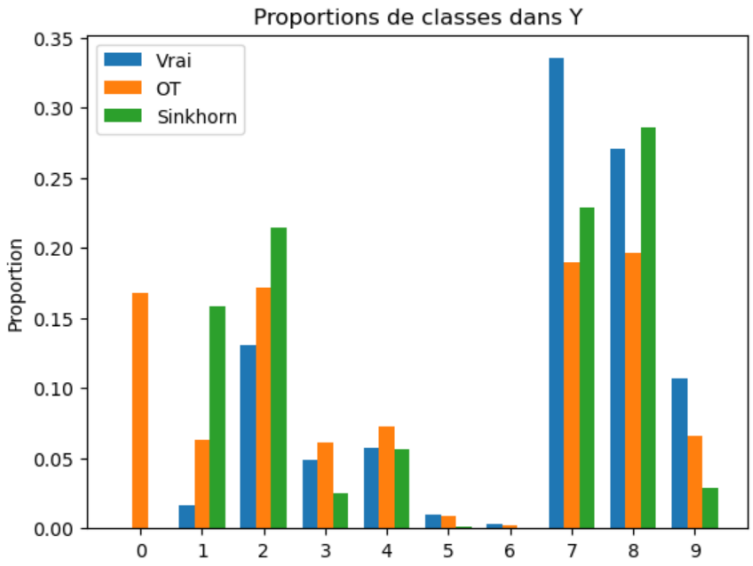


FIGURE 1 – Proportions de classes estimées : OT exact, Sinkhorn et valeurs réelles.

3.3 Impact de la régularisation et analyse des ARI

Pour évaluer quantitativement la qualité des classifications obtenues par transport optimal, nous utilisons l'Adjusted Rand Index (ARI). L'ARI est une mesure de similarité entre deux partitions d'un même ensemble de données, indépendante de la permutation des labels. Il varie entre -1 et 1.

Cette métrique permet de comparer les classes prédites pour les observations cibles avec le clustering réel connu sur le jeu de données source ou cible.

Les indices ARI obtenus sont les suivants :

$$\text{ARI (OT exact)} = 0.449, \quad \text{ARI (Sinkhorn, } \varepsilon = 0.05) = 0.514.$$

On constate que, pour ce jeu de données, l'ARI associé au transport régularisé est supérieur ou au moins égal à celui obtenu avec le transport exact, indiquant une qualité de classification comparable, voire légèrement améliorée grâce à la régularisation.

Afin d'étudier l'influence du paramètre de régularisation ε, l'ARI a été calculé pour $\varepsilon \in \{10^{-3}, 5\cdot10^{-3}, 10^{-2}, 5\cdot10^{-2}, 10^{-1}\}$. La Figure 2 illustre l'évolution de l'ARI en fonction de ε. Remarquons que la figure ne présente que quelques valeurs de ε car le calcul complet est coûteux et a été interrompu après ces évaluations ponctuelles.

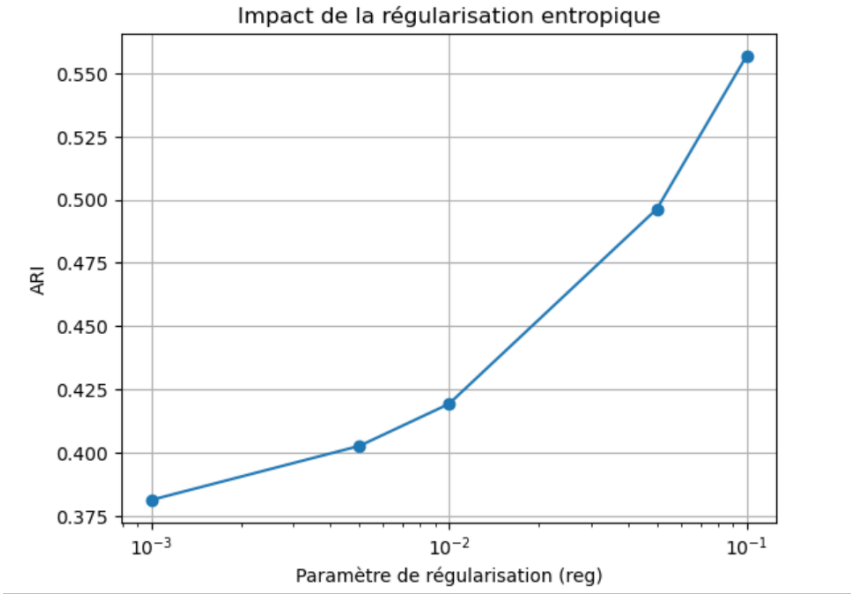


FIGURE 2 – Évolution de l'ARI en fonction du paramètre de régularisation ε.

On observe les tendances suivantes :

— Pour de petites valeurs de ε, le plan régularisé se comporte presque comme le transport exact, avec un ARI similaire, mais le temps de calcul reste élevé.

— Pour des valeurs modérées de ε, l'ARI atteint un maximum, traduisant un compromis optimal entre fidélité géométrique et stabilité numérique.

— Pour des valeurs trop grandes, le plan devient diffus et la qualité de la classification se dégrade légèrement, entraînant une baisse de l'ARI.

Ces résultats confirment que la régularisation entropique permet non seulement de réduire le coût computationnel, mais aussi de stabiliser la classification, avec un paramètre ε correctement choisi offrant le meilleur compromis entre précision et robustesse.

3.4 Comparaison visuelle des classifications

La Figure 3 présente une comparaison visuelle des classifications des observations cible : à gauche, les vraies classes ; au centre, les classes prédites par le transport optimal exact ; à droite, les classes prédites par le transport régularisé par Sinkhorn pour le paramètre ε optimal.

On observe que le transport optimal exact produit une classification moins précise, avec des correspondances souvent incorrectes par rapport aux vraies classes. En revanche, l'algorithme de Sinkhorn permet une amélioration notable de la qualité de la classification, les classes prédites se rapprochant beaucoup des classes réelles. Cette comparaison visuelle illustre clairement l'effet bénéfique de la régularisation entropique sur la précision des classifications tout en conservant un coût computationnel réduit.

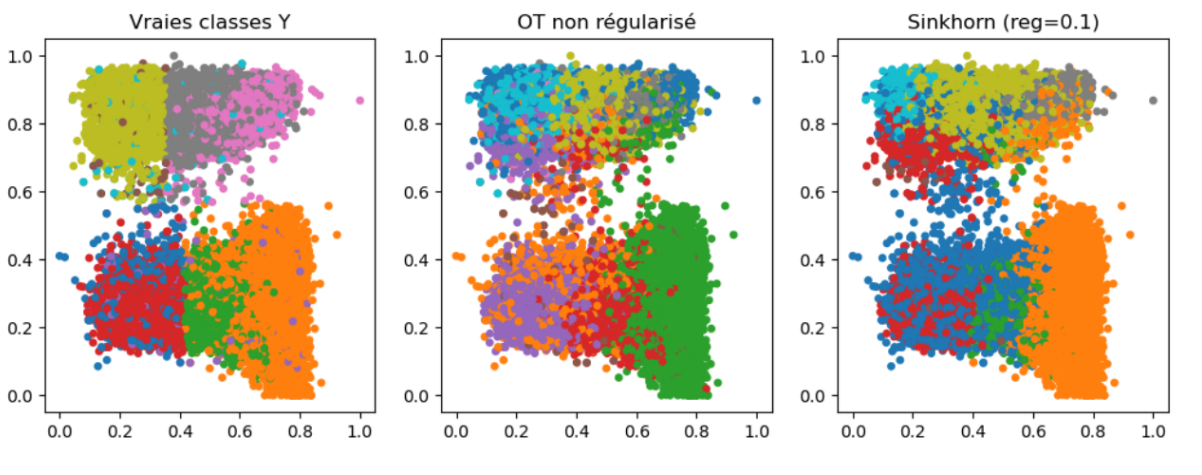


FIGURE 3 – Comparaison visuelle des classifications : (gauche) vraies classes, (centre) OT exact, (droite) Sinkhorn (ε optimal).

4 Conclusion

L'introduction de la régularisation entropique via Sinkhorn permet de calculer un plan de transport rapidement et de façon stable, tout en conservant une qualité de classification comparable au transport exact. Elle illustre le compromis biais–variance : régularisation modérée = plan stable et fidèle, régularisation excessive = plan lissé et classification dégradée. Pour des applications à grande échelle comme la cytométrie en flux, cette approche constitue une solution robuste et efficace pour la classification supervisée.