Synthèse scientifique de l'article : *Fast Computation of Wasserstein Barycenters*

Souleyman — Master Mathématiques Appliquées et Statistique, Université de Bordeaux
Parcours : Modélisation Statistique et Stochastique (MSS)
UE : Numérics MAS1
Tuteur : Jérémie Bigot
Auteurs de l'article : Marco Cuturi et Arnaud Doucet
Accès : http://proceedings.mlr.press/v32/cuturi14.pdf

06 Novembre 2025

1. Situation et contexte général

L'article intitulé *Fast Computation of Wasserstein Barycenters*, rédigé par Marco Cuturi et Arnaud Doucet, fut publié en 2014 dans les *Proceedings of the 31st International Conference on Machine Learning (ICML)*, à Pékin. Il est édité par le *Proceedings of Machine Learning Research (PMLR)*, volume 32, pages 685–693. Ce travail s'inscrit dans le domaine du transport optimal et de l'apprentissage statistique, en proposant une méthode rapide pour le calcul du **barycentre de Wasserstein**, c'est-à-dire la moyenne géométrique d'un ensemble de distributions de probabilité sous la métrique du transport optimal. ICML, conférence internationale de référence en apprentissage automatique, confère à cette publication un impact scientifique élevé et une grande visibilité académique.

2. Les auteurs et leurs contributions

Marco Cuturi, alors affilié à la Kyoto University (Graduate School of Informatics), est aujourd'hui professeur à l'ENSAE–CREST et chercheur principal chez Apple. Spécialiste du transport optimal, il a introduit la régularisation entropique et l'algorithme de Sinkhorn, deux outils centraux de l'article. Arnaud Doucet, professeur de statistique à l'Université d'Oxford et chercheur chez Google DeepMind, est reconnu mondialement pour ses travaux en inférence bayésienne, méthodes de Monte Carlo et statistique computationnelle. Leur collaboration combine rigueur mathématique et expertise numérique, apportant une solution computationnelle robuste à un problème auparavant jugé intractable.

3. Popularité et portée scientifique du sujet

Avec plus de 1000 citations sur Google Scholar (octobre 2025), l'article est devenu une référence en transport optimal computationnel. Avant 2014, le calcul des barycentres de Wasserstein restait un problème essentiellement théorique. Après cette publication, le domaine a connu un essor considérable, avec des applications directes en apprentissage profond, en traitement d'images et en modélisation probabiliste, notamment via les *Wasserstein GANs* et les barycentres entropiques.

4. Cadre scientifique et état de l'art

Les travaux s'appuient sur trois contributions majeures antérieures : Agueh et Carlier (2011), qui introduisent la définition théorique du barycentre de Wasserstein et prouvent son existence et son unicité ; Rabin et al. (2012), qui proposent un calcul numérique pour des espaces euclidiens de faible dimension ; et Cuturi (2013), qui introduit la régularisation entropique du transport optimal. L'article de 2014 s'inscrit donc comme une extension naturelle de ces travaux, combinant la rigueur théorique d'Agueh et Carlier avec l'efficacité algorithmique issue de la régularisation de Cuturi.

5. Fondements théoriques

La distance de Wasserstein entre deux mesures de probabilité μ et ν est définie par :

$$W_p(\mu,\nu) = \left(\inf_{\pi \in \Pi(\mu,\nu)} \int_{\Omega^2} D(x,y)^p \, d\pi(x,y) \right)^{1/p},$$

où $\Pi(\mu,\nu)$ représente l'ensemble des plans de transport admissibles. Cette distance mesure le coût minimal pour transporter la masse de la mesure μ vers la mesure ν en utilisant la métrique D.

Dans cet article, les auteurs se sont restreints aux mesures empiriques. Ainsi, pour des mesures discrètes $\mu = \sum_i a_i \delta_{x_i}$ et $\nu = \sum_j b_j \delta_{y_j}$, on obtient :

$$W_p^p(\mu,\nu) = \min_{T \in U(a,b)} \langle T, M_{XY} \rangle,$$

$$U(a,b) = \{T \geq 0 \mid T1_m = a,\, T^T 1_n = b\}.$$

Le barycentre de Wasserstein de N distributions $\nu_1, \ldots, \nu_N$ est la solution du problème :

$$\mu^\star = \arg\min_{\mu} \frac{1}{N} \sum_{i=1}^{N} W_p^p(\mu, \nu_i),$$

formellement équivalent à une moyenne géométrique dans l'espace des mesures de probabilité muni de la distance W_p.

5.1. Synthèse des travaux récents

Agueh et Carlier (2011) ont étudié les conditions d'unicité du barycentre de Wasserstein à l'aide du problème

de transport multi-marginal, en proposant des solutions explicites pour certains cas particuliers, notamment pour les mesures gaussiennes. Rabin et al. (2012) ont ensuite introduit une approche computationnelle efficace basée sur la *distance de Wasserstein tranchée*, permettant de calculer rapidement des barycentres dans des espaces de faible dimension, bien que cette méthode soit limitée lorsque la dimension $d \geq 4$ ou dans les espaces non euclidiens.

6. Méthodologie et motivation

L'objectif principal des auteurs est de rendre le calcul des barycentres de Wasserstein à la fois **rapide**, **stable** et **différentiable**. Les méthodes classiques reposant sur le transport optimal sont précises mais trop coûteuses ($O(n^3)$). Pour surmonter cette limite, Cuturi et Doucet introduisent une **régularisation entropique** qui :

— rend la fonction objectif **lisse et strictement convexe**, facilitant les calculs de gradient ;

— permet l'utilisation de l'**algorithme de Sinkhorn**, basé sur une mise à l'échelle matricielle rapide ($O(n^2)$) ;

— conserve une interprétation géométrique cohérente du barycentre de Wasserstein.

La version régularisée du problème s'écrit :

$$p_\lambda(a, b; M) = \min_{T \in U(a,b)} \langle T, M \rangle - \frac{1}{\lambda} h(T),$$

avec

$$h(T) = -\sum_{i,j} t_{ij} \log t_{ij}.$$

Le problème dual associé est :

$$d_\lambda(a, b; M) = \max_{\alpha,\beta} \alpha^T a + \beta^T b - \frac{1}{\lambda} \sum_{i,j} e^{-\lambda(m_{ij} - \alpha_i - \beta_j)}.$$

Les solutions optimales prennent la forme :

$$T^*_\lambda = \mathrm{diag}(u) K \mathrm{diag}(v), \quad K = e^{-\lambda M},$$

obtenues par les mises à jour itératives :

$$u \leftarrow \frac{a}{Kv}, \quad v \leftarrow \frac{b}{K^T u}.$$

Cette régularisation entropique rend le calcul des barycentres beaucoup plus efficace et stable numériquement.

7. Algorithmes de calcul du barycentre

Les auteurs proposent deux variantes principales selon la nature du support du barycentre : **fixe** ou **libre**.

7.1. Cas du support fixe

Lorsque le support X est fixé, seuls les poids a sont mis à jour. L'objectif est alors une fonction convexe de a, optimisée par une **méthode de sous-gradient** avec **projection de Bregman**. La mise à jour prend la forme :

$$a \leftarrow \mathrm{proj}_\Theta \left(a - t_0 \nabla f(a) \right),$$

avec une version multiplicative dans le simplexe :

$$a \leftarrow a \odot \exp(-t_0 \alpha); \quad a \leftarrow \frac{a}{\sum_j a_j}.$$

Cette méthode bénéficie d'une convergence accélérée grâce à l'**accélération de Nesterov**.

7.2. Cas du support libre

Lorsque les positions X du support sont libres, les auteurs combinent deux étapes :

1. **Mise à jour des poids** a : selon l'approche précédente (support fixe).
2. **Mise à jour des positions** X : à partir des plans de transport optimaux T^*_i, selon :

$$X \leftarrow (1 - \theta) X + \theta \left(\frac{1}{N} \sum_{i=1}^{N} Y_i T_i^{*T} \mathrm{diag}(a^{-1}) \right),$$

où θ est un paramètre d'apprentissage.

Cette seconde étape généralise le principe du **k-means**, chaque centroïde étant mis à jour comme un barycentre pondéré selon les transports optimaux. Ainsi, la méthode de Cuturi et Doucet combine efficacité numérique et interprétation géométrique claire du problème.

8. Résultats expérimentaux et impact

Les auteurs illustrent l'efficacité de leurs méthodes sur deux jeux de données distincts, en séparant les cas de **support fixe** et **support libre**.

8.1. Support fixe : Visualisation d'images (MNIST)

— **Données** : 50 000 images du dataset MNIST (chiffres manuscrits 0–9), chacune représentée comme une mesure empirique sur une grille 100×100.

— **Objectif** : Calculer le barycentre de Wasserstein pour chaque chiffre (10 classes), avec un support fixe X correspondant à la grille d'images.

— **Méthode** : L'Algorithme 1 est appliqué avec une régularisation entropique ($\lambda = 60/\mathrm{median}(M)$), où M est la matrice des distances euclidiennes au carré entre pixels.

— **Résultats** :

  — Les barycentres obtenus après 60 itérations capturent la structure géométrique des chiffres, contrairement aux moyennes euclidiennes ou aux centroids de Jeffrey.

  — **Temps de calcul** : Environ 2 heures pour 100 itérations sur un GPU (Quadro K5000), avec une accélération significative grâce à la parallélisation de l'algorithme de Sinkhorn.

— **Impact** : Démonstration de la capacité des barycentres de Wasserstein à **préserver la structure géométrique** des données, même en haute dimension.

8.2. Support libre : Clustering de données de recensement

- **Données** : 57 647 localisations dans les 48 États contigus des États-Unis, avec deux mesures empiriques ν_1 et ν_2 représentant respectivement la répartition du **revenu** et de la **population**.
- **Objectif** : Trouver 48 centroïdes ($k = 48$) qui résument ces données, en comparant :
  - Un clustering **libre** (équivalent au k-means, $\Theta = \Sigma_k$).
  - Un clustering **uniforme** (poids contraints à $\Theta = \{\frac{1}{k}\mathbf{1}_k\}$).
- **Méthode** : L'Algorithme 2 est initialisé avec les capitales des 48 États. La régularisation entropique permet de calculer les plans de transport optimaux en temps réduit (12,5 secondes par itération pour le cas uniforme vs 1,55 seconde pour le k-means classique).
- **Résultats** :
  - Les centroïdes uniformes (contrainte $\Theta = \{\frac{1}{k}\mathbf{1}_k\}$) induisent un **clustering équilibré**, où chaque centroïde représente une part égale de la masse totale (revenu ou population).
  - La distance de Wasserstein entre les clusters et les données originales est plus élevée pour le cas uniforme, en raison des contraintes, mais la répartition est plus juste.
  - **Convergence** : L'Algorithme 2 converge aussi rapidement que le k-means en nombre d'itérations, avec un surcoût computationnel modéré.
- **Impact** : Illustration de la **flexibilité** des barycentres de Wasserstein pour imposer des contraintes arbitraires sur les poids, utile pour des applications comme le déploiement de ressources ou la planification urbaine.

8.3. Avantages et limites

- **Avantages** :
  - Réduction du temps de calcul de **plusieurs ordres de grandeur** (de heures à secondes/minutes) grâce à la régularisation entropique.
  - **Scalabilité** : Traitement de dizaines de milliers de points (ex. : 57 647 localisations pour le recensement).
  - **Flexibilité** : Possibilité d'imposer des contraintes sur les poids (ex. : uniformité, entropie minimale).
- **Limites** :
  - **Convergence lente** des méthodes de sous-gradient sans régularisation.
  - **Sensibilité au paramètre** λ : Un λ trop petit ou trop grand peut dégrader la qualité des solutions ou la stabilité numérique.

9. Portée scientifique

L'originalité de cette contribution réside dans :

- L'**usage conjoint** de la régularisation entropique et de l'optimisation alternée, transformant un problème théorique complexe en un outil **computationnellement efficace**.
- La **capture de la géométrie intrinsèque** de l'espace des probabilités, contrairement aux barycentres euclidiens ou aux méthodes basées sur des noyaux, qui ignorent souvent la structure métrique sous-jacente.
- Une **portée générale** : la méthode s'étend à d'autres problèmes variationnels impliquant des distances de Wasserstein, comme les **Wasserstein GANs** ou le **clustering géométrique**.

Cet article est considéré comme **fondateur** pour le domaine du *transport optimal computationnel*, ouvrant la voie à des applications en apprentissage automatique, traitement d'images, et analyse de données massives.

10. Conclusion

L'article de Cuturi et Doucet (2014) marque un tournant dans le domaine du transport optimal en proposant une **solution pratique et scalable** à un problème auparavant prohibitif. Grâce à une idée simple mais puissante — la **régularisation entropique** — les auteurs transforment la résolution des barycentres de Wasserstein en un processus efficace, compatible avec des données de grande dimension. Le couplage entre **rigueur mathématique** (garanties de convergence, convexité stricte) et **performance algorithmique** (accélération GPU, complexité réduite) en fait une contribution majeure, durablement ancrée dans les fondations de la **statistique computationnelle** et de l'**apprentissage automatique**.

Mots-clés : Wasserstein barycenter, optimal transport, Sinkhorn algorithm, entropic regularization, clustering, machine learning, convex optimization.

Référence :

Cuturi, M. & Doucet, A. (2014). *Fast Computation of Wasserstein Barycenters*. Proceedings of the 31st ICML, PMLR 32(2) :685–693.